

Analisis Data Eksoplanet Tahun 2014 dan 2016 menggunakan Exploratory Data Analysis (EDA)

Maria Putu Evelyne Corena Puryatma – 5054251011

ABSTRAK

Eksoplanet adalah planet yang mengorbit bintang selain Matahari. Data eksoplanet yang tersedia di internet biasanya merupakan gabungan dari beberapa cara penemuan yang berbeda, dan setiap cara hanya bisa mengukur sebagian hal saja. Akibatnya data seperti ini sering punya banyak sel kosong, angkanya melompat sangat jauh antara yang terkecil dan terbesar, serta jumlah tiap kategorinya tidak seimbang. Tugas ini bertujuan mengenali isi dan masalah pada data eksoplanet menggunakan Exploratory Data Analysis (EDA). Datanya diambil dengan cara scraping dari dua halaman Wikipedia, yaitu daftar eksoplanet yang ditemukan tahun 2014 dan 2016, dan hasilnya berupa 2.367 baris dengan 11 kolom. Pemeriksaan yang dilakukan meliputi tipe data, jumlah nilai unik, baris kembar, pola nilai kosong, pencarian nilai ekstrem dengan metode IQR pada skala biasa dan skala log, bentuk sebaran tiap kolom, serta hubungan antarkolom memakai korelasi Pearson dan Spearman yang dicek juga dengan Hukum Kepler III. Hasilnya, data tidak punya baris kembar, tetapi hanya 78 baris (3,3%) yang terisi penuh. Nilai kosongnya ternyata mengikuti cara penemuan: planet transit tidak punya data massa sebanyak 92%, sedangkan planet radial velocity tidak punya data radius sebanyak 99%. Ada 626 baris yang dianggap outlier oleh IQR, tetapi jumlahnya turun jauh kalau dihitung pada skala log, jadi sebagian besar hanya efek sebaran yang miring. Metode transit mengisi 94,4% data dan 87,3% planetnya berasal dari misi Kepler, sehingga data ini lebih menggambarkan satu misi saja daripada planet di alam semesta pada umumnya. Korelasi periode orbit dengan sumbu semimayor mencapai 0,99 dan 745 planet punya nilai rasio Kepler III sekitar 1,006, artinya isi datanya cukup konsisten. Semua temuan ini dirangkum menjadi tujuh masalah yang perlu ditangani pada tahap preprocessing.

Kata kunci: *exploratory data analysis, eksoplanet, web scraping, nilai kosong, outlier, metode deteksi*

1 Latar Belakang

Daftar eksoplanet yang bisa diakses umum, baik lewat NASA Exoplanet Archive maupun Wikipedia, bukan hasil satu alat saja tetapi gabungan dari beberapa cara penemuan. Masalahnya, setiap cara hanya bisa mengukur hal yang berbeda. Cara transit bisa menghitung ukuran (radius) planet tetapi tidak bisa tahu beratnya. Cara radial velocity kebalikannya, bisa memperkirakan berat planet tetapi tidak tahu ukurannya. Cara microlensing bisa menemukan planet yang sangat jauh, tetapi kejadiannya hanya terjadi sekali sehingga bentuk orbitnya sering tidak bisa dihitung. Karena itu, data gabungan seperti ini sudah pasti punya banyak sel kosong, dan kosongnya tidak asal-asalan melainkan tergantung planetnya ditemukan dengan cara apa.

Data dengan sifat seperti ini cocok dianalisis dengan Exploratory Data Analysis (EDA), yaitu cara mengenali data lebih dulu lewat ringkasan angka dan grafik sebelum kita memutuskan mau dipakai untuk model apa. Nilai kosong perlu dipahami sejak awal karena cara menanganinya tergantung penyebabnya. Kalau kolom massa kosong pada planet transit, itu bukan karena datanya hilang, tetapi karena metodenya memang tidak bisa mengukur massa. Jadi menghapus semua baris yang ada kosongnya justru akan membuang hampir seluruh data.

Hal kedua yang perlu diperhatikan adalah angka-angka ekstrem. Di astronomi, angka yang kelihatannya aneh sering kali benar adanya, hanya saja berasal dari jenis objek yang berbeda. Contohnya objek dengan berat di atas sekitar 13 kali massa Jupiter, yang biasanya sudah dianggap bukan planet lagi melainkan katai coklat. Contoh lain adalah adanya celah pada sebaran ukuran planet kecil, serta hubungan antara berat dan ukuran planet yang tidak berbentuk garis lurus. Karena itu, angka ekstrem tidak boleh langsung dihapus tanpa dipahami dulu artinya.

Tujuan tugas ini ada empat, yaitu mengambil data eksoplanet tahun 2014 dan 2016 lewat scraping dengan cara yang tidak melanggar aturan situs, mengenali isi data mulai dari nilai kosong, bentuk sebaran, sampai nilai ekstremnya, mengecek apakah isi datanya masuk akal secara fisika, dan terakhir membuat daftar masalah yang perlu dibereskan di tahap preprocessing. Perlu ditegaskan bahwa tugas ini hanya sampai tahap mengenali data. Tidak ada kolom yang dihapus, tidak ada baris yang dibuang, dan tidak ada nilai kosong yang diisi.

2 Metodologi

2.1 Cara Mengambil Data

Data diambil dengan scraping dari dua halaman Wikipedia, yaitu *List of exoplanets discovered in 2014* dan *List of exoplanets discovered in 2016*, memakai pustaka requests untuk mengambil halaman dan BeautifulSoup untuk membaca isi tabelnya. Supaya prosesnya tidak merugikan situs sumber, ada beberapa pengaman yang dipakai: alamat yang diterima hanya yang memakai HTTPS dan berasal dari en.wikipedia.org; berkas robots.txt dicek dulu sebelum halaman diambil dan proses dihentikan kalau tidak diizinkan; User-Agent diisi apa adanya dengan batas waktu tunggu 30 detik dan batas ukuran balasan 5 MB; jumlah permintaan dijaga hanya dua halaman dengan jeda satu detik; serta sumbernya dicantumkan sesuai lisensi CC BY-SA.

Untuk membaca isi tabel dibuat dua fungsi bantu. Fungsi teks_sel() mengambil tulisan di dalam sel sekaligus membuang tanda rujukan seperti yang banyak ada di Wikipedia. Fungsi angka_atau_none() mengambil angka pertama yang ditemukan, dan kalau tidak ada angka sama sekali maka hasilnya dianggap kosong. Dengan begitu sel yang memang kosong tidak membuat programnya berhenti. Hasil akhirnya 2.367 baris dan 11 kolom, dengan keterangan tiap kolom ada di Tabel 1. Sebelum dipakai, datanya dicek dulu memakai assert untuk memastikan jumlah barisnya cukup, nama planetnya tidak ada yang sama, serta periode dan jaraknya bernilai positif. Semua pengecekan lolos.

Tabel 1. Keterangan kolom pada data eksoplanet

Kolom	Satuan	Keterangan	Kolom	Satuan	Keterangan
nama	—	Nama planet	metode_deteksi	—	Cara planet ditemukan
massa_mj	massa Jupiter	Berat planet	jarak_tahun_cahaya	tahun cahaya	Jarak dari Bumi
radius_rj	radius Jupiter	Ukuran planet	massa_bintang_msun	massa Matahari	Berat bintang induk
periode_hari	hari	Lama satu kali mengorbit	suhu_bintang_k	Kelvin	Suhu bintang induk
sumbu_semi_mayor_au	AU	Jarak planet ke bintangnya	tahun_penemuan	tahun	Bernilai 2014 atau 2016
suhu_planet_k	Kelvin	Suhu planet			

2.2 Alat dan Beberapa Keputusan saat Analisis

Analisis dikerjakan di Jupyter Notebook memakai pandas, numpy, matplotlib, dan seaborn. Warna grafik dibuat sama sepanjang notebook, yaitu biru untuk grafik satu warna dan untuk kategori transit, oranye untuk radial velocity, dan hijau kebiruan untuk kategori gabungan lainnya. Ketiga warna ini dipilih supaya tetap bisa dibedakan oleh pembaca yang buta warna.

Urutan analisisnya mengikuti langkah EDA pada umumnya: memuat data, cek tipe data, menandai kolom yang kurang berguna, cek nama kolom, cek baris kembar, cek nilai kosong, cari outlier, lihat sebaran tiap kolom, lalu lihat hubungan antarkolom. Bedanya, di sini setiap langkah hanya mencatat tanpa mengubah datanya. Ada beberapa keputusan yang perlu dijelaskan:

1. Skala log dipakai untuk massa_mj, radius_rj, periode_hari, sumbu_semimayor_au, dan jarak_tahun_cahaya karena angkanya beda jauh sekali, misalnya dari 0,5 hari sampai 11.613 hari. Kalau memakai skala biasa, grafiknya jadi tidak terbaca. Tiga kolom sisanya tetap memakai skala biasa karena rentangnya tidak terlalu lebar.
2. IQR dihitung dua kali, yaitu pada skala biasa dan pada skala log, supaya bisa dibedakan mana yang benar-benar angka aneh dan mana yang hanya kelihatan aneh karena sebarannya miring.
3. Pearson dan Spearman dipakai bersamaan. Pearson mengukur hubungan yang berbentuk garis lurus, sedangkan Spearman mengukur hubungan yang searah walaupun bentuknya melengkung. Kalau kedua nilainya beda jauh, berarti hubungannya tidak lurus atau terpengaruh angka ekstrem.
4. Hukum Kepler III dipakai untuk mengecek apakah isi datanya masuk akal, dengan rumus a^3 dibagi (P^2 dikali M). Kalau datanya benar, hasilnya harusnya mendekati 1. Nilai di luar rentang 0,5 sampai 2 dianggap mencurigakan.
5. Pada scatterplot, kategori microlensing, timing, dan imaging digabung jadi "lainnya" karena jumlahnya cuma 27 planet. Batas 13 MJ dipakai sebagai patokan pemisah antara planet dan katai coklat.

3 Hasil dan Pembahasan

3.1 Bentuk Data, Tipe, dan Baris Kembar

Datanya berukuran 2.367 baris dan 11 kolom. Dari lima baris pertama saja sudah kelihatan polanya: tiga planet radial velocity di urutan atas punya data berat tetapi kosong di kolom ukuran dan suhu planet, sedangkan dua planet transit (COROT) datanya terisi lengkap. Urutan barisnya juga rapi, yaitu diurutkan per tahun dulu lalu berdasarkan abjad nama, sama seperti urutan di tabel aslinya.


Delapan kolom angka semuanya sudah bertipe float, jadi tidak ada angka yang kesimpang sebagai teks dan tidak perlu diubah tipenya. Kolom nama punya 2.367 nilai berbeda, sama persis dengan jumlah barisnya, artinya kolom ini cuma berfungsi sebagai penanda dan tidak bisa dipakai untuk analisis. Kolom metode_deteksi cuma punya 5 pilihan dan tahun_penemuan cuma punya 2 pilihan, jadi sebaiknya tahun_penemuan diperlakukan sebagai kategori meskipun tipenya angka. Nama kolomnya sudah pakai format snake_case dan sudah ada satuannya, jadi tidak perlu diganti. Cuma perlu diingat satuan berat planet (MJ) dan berat bintang (Msun) berbeda, jadi keduanya tidak bisa langsung dibandingkan. Untuk baris kembar hasilnya bersih: tidak ada baris yang isinya sama persis dan tidak ada nama planet yang muncul dua kali. Ringkasan lengkap tiap kolom ada di Tabel 2.

Tabel 2. Ringkasan tiap kolom: tipe data, jumlah nilai berbeda, jumlah terisi, dan persen kosong

Kolom	Tipe	Beda	Terisi	Kosong %	Kolom	Tipe	Beda	Terisi	Kosong %
nama	object	2.367	2.367	0,0	metode_deteksi	object	5	2.367	0,0
massa_mj	float64	265	299	87,4	jarak_tahun_cahaya	float64	648	2.291	3,2
radius_rj	float64	525	2.240	5,4	massa_bintang_msun	float64	150	2.101	11,2
periode_hari	float64	2.348	2.348	0,8	suhu_bintang_k	float64	1.188	2.340	1,1
sumbu_semimayor_au	float64	531	1.018	57,0	tahun_penemuan	int64	2	2.367	0,0
suhu_planet_k	float64	95	104	95,6					


3.2 Nilai Kosong

Dari 11 kolom, ada 8 kolom yang punya nilai kosong. Cuma nama, metode_deteksi, dan tahun_penemuan yang terisi penuh. Gambar 1 menunjukkan berapa persen kosongnya tiap kolom sekaligus berapa banyak kolom yang kosong dalam satu baris.




Gambar 1. Gambaran nilai kosong: (a) persen kosong tiap kolom, (b) jumlah kolom kosong dalam satu baris

Tingkat kosongnya bisa dibagi empat kelompok. Paling parah suhu_planet_k (95,6%) dan massa_mj (87,4%). Cukup parah sumbu_semimayor_au (57,0%). Sedang massa_bintang_msun (11,2%). Sisanya ringan, yaitu radius_rj (5,4%), jarak_tahun_cahaya (3,2%), suhu_bintang_k (1,1%), dan periode_hari (0,8%). Panel (b) menunjukkan hal yang paling penting: cuma 78 baris atau 3,3% yang terisi penuh, sementara sebagian besar (1.620 baris) kosong di tepat tiga kolom. Artinya kalau kita langsung pakai dropna(), 96,7% datanya akan hilang dan sisanya tidak lagi mewakili data aslinya.



Gambar 2. Peta nilai kosong di seluruh baris (biru berarti kosong), diurutkan per tahun lalu per metode

Kosongnya membentuk blok-blok rapi. Kolom sumbu_semimayor_au hampir penuh di bagian 2014 tetapi hampir kosong semua di bagian 2016, dan massa_bintang_msun polanya kebalikan. Baris paling atas tiap tahun, yang isinya planet non-transit, polanya beda lagi yaitu radius_rj kosong sedangkan massa_mj terisi. Pola kotak-kotak seperti ini menandakan kosongnya dipengaruhi kolom lain yang bisa kita lihat, bukan kosong secara acak [7].



Gambar 3. Persen nilai kosong pada tiap metode deteksi

Gambar 3 membuktikan bahwa kosongnya mengikuti kemampuan tiap metode. Transit mengukur ukuran planet dari seberapa dalam cahaya bintang meredup, dan memang tidak bisa mengukur berat, jadi massa_mj kosong pada 92% planet transit. Sebaliknya radial velocity menghitung berat dari goyangan bintang tetapi tidak bisa tahu ukurannya, jadi radius_rj kosong pada 99% planetnya. Microlensing tidak menghasilkan periode, ukuran, maupun suhu bintang (kosong 92-100%), karena kejadiannya cuma sekali dan bintangnya sangat jauh. Imaging sama sekali tidak punya periode_hari karena planetnya mengorbit sangat lebar sehingga satu putaran butuh waktu jauh lebih lama daripada lama pengamatan. Sementara suhu_planet_k kosong di semua metode (80-100%) karena suhu ini bukan hasil ukur langsung melainkan hasil hitungan.


Selain metode, tahun juga berpengaruh (Tabel 3). Kolom sumbu_semimayor_au cuma kosong 7,0% di tahun 2014 tetapi melonjak jadi 86,0% di tahun 2016. Kebalikannya, massa_bintang_msun kosong 29,2% di 2014 tetapi cuma 0,8% di 2016. Selisih sebesar ini tidak mungkin karena sifat planetnya, tetapi karena tabel sumbernya memang beda kelengkapan. Jadi kolom tahun_penemuan sebenarnya juga menyimpan informasi tentang seberapa lengkap pencatatannya, bukan cuma informasi astronomi.

Tabel 3. Persen nilai kosong tiap kolom menurut metode deteksi dan tahun penemuan

Kolom	transit(2.235)	radial vel.(105)	micro.(13)	timing(9)	imaging(5)	2014(869)	2016(1.498)
massa_mj	92	0	0	11	20	83,0	89,9
radius_rj	0	99	100	33	40	7,1	4,3
periode_hari	0	0	92	0	100	0,9	0,7
sumbu_semimayor_au	59	15	0	78	0	7,0	86,0
suhu_planet_k	96	94	100	100	80	95,2	95,9
jarak_tahun_cahaya	3	3	0	11	0	0,0	5,1
massa_bintang_msun	12	0	0	0	0	29,2	0,8
suhu_bintang_k	0	1	100	44	20	2,1	0,6

3.3 Mencari Outlier

Outlier dicari memakai boxplot dan metode IQR, tanpa menghapus data sama sekali. Pada skala biasa, kotak boxplot periode_hari dan sumbu_semimayor_au gepeng jadi garis tipis gara-gara ada nilai 11.613 hari dan 6.900 AU, jadi sebarannya sama sekali tidak terbaca. Karena itu Gambar 4 memakai skala log.



Gambar 4. Boxplot kolom-kolom angka pada skala log

Di skala log, sebaran periode_hari, sumbu_semimayor_au, dan massa_mj baru kelihatan jelas menyebar sangat lebar. Sebaliknya massa_bintang_msun dan suhu_bintang_k justru kelihatan sempit dan menumpuk di sekitar nilai bintang yang mirip Matahari, dengan beberapa outlier di kedua sisi. Kolom jarak_tahun_cahaya punya ekor ke kiri berisi bintang dekat dan ekor ke kanan berisi objek microlensing. Hitungan IQR-nya ada di Tabel 4.

Tabel 4. Hasil hitungan IQR dan jumlah outlier pada skala biasa dan skala log


Kolom	Q1	Q3	IQR	Batas bawah	Batas atas	Outlier	%	Outlier (log)
massa_mj	0,085	2,151	2,066	-3,014	5,250	38	12,7	2
radius_rj	0,132	0,255	0,123	-0,052	0,440	213	9,5	158
periode_hari	4,634	26,681	22,047	-28,437	59,751	289	12,3	67
sumbu_semimayor_au	0,057	0,182	0,125	-0,130	0,369	121	11,9	66
suhu_planet_k	822,8	1.604,3	781,5	-349,5	2.776,5	0	0,0	2
jarak_tahun_cahaya	1.437	3.230	1.793	-1.252,5	5.919,5	37	1,6	133
massa_bintang_msun	0,840	1,070	0,230	0,495	1,415	111	5,3	175
suhu_bintang_k	5.178	5.935	757	4.042,5	7.070,5	111	4,7	142

Total ada 626 baris (26,4%) yang punya minimal satu outlier menurut IQR pada skala biasa, paling banyak di massa_mj (12,7%), periode_hari (12,3%), sumbu_semimayor_au (11,9%), dan radius_rj (9,5%). Ada dua hal yang perlu dicatat dari tabel ini. Pertama, batas bawahnya bernilai negatif padahal berat, ukuran, periode, dan jarak tidak mungkin negatif, jadi di kolom-kolom itu yang masuk akal cuma outlier di sisi atas. Kedua, kalau IQR dihitung pada skala log jumlah outliernya

turun drastis, misalnya periode_hari dari 289 jadi 67 dan massa_mj dari 38 jadi 2. Ini membuktikan sebagian besar "outlier" tadi sebenarnya adalah efek sebaran yang miring, bukan data yang salah.

Waktu nilai-nilai terbesarnya dicek satu per satu, semuanya berasal dari metode yang jumlahnya sedikit. Planet 2MASS J2126-8140 (imaging) memang mengorbit sejauh 6.900 AU dari bintangnya. Objek berawalan OGLE (microlensing) memang berjarak 26.000-27.000 tahun cahaya karena survei microlensing diarahkan ke pusat galaksi. Planet HD 30177 c (radial vel.) memang butuh 11.613 hari atau sekitar 32 tahun untuk satu kali mengorbit, dan HD 100546 b (imaging) memang berukuran 3,40 RJ dengan bintang bersuhu 10.500 K. Ada enam objek dengan berat di atas 13 MJ, yaitu HR 2562 b (30 MJ), HIP 97233 b, 2MASS J2126-8140, HD 214823 b, HD 219828 c, dan WASP-53c, yang kemungkinan besar sebenarnya katai coklat, bukan planet. Jadi outlier di data ini bukan salah input, melainkan tanda bahwa isinya campuran beberapa jenis objek. Kalau outliernya dihapus otomatis, semua metode minoritas akan ikut hilang.

3.4 Sebaran Kolom Kategori




Gambar 5. Sebaran kolom kategori: (a) metode deteksi, (b) tahun penemuan, (c) awalan nama katalog

Metode transit mendominasi habis-habisan dengan 2.235 planet atau 94,4%. Radial velocity cuma 105 planet (4,4%), sedangkan microlensing (13), timing (9), dan imaging (5) masing-masing di bawah 1%. Ketimpangan sebesar ini bikin dua masalah. Pertama, kategori yang cuma berisi 5 sampai 13 planet terlalu sedikit untuk dianalisis sendiri. Kedua, semua rata-rata dan statistik yang kita hitung dari data ini sebenarnya adalah statistik planet transit. Untuk tahunnya, 2016 menyumbang 1.498 planet (63%), hampir dua kali lipat 2014 yang 869 planet, dan kenaikannya hampir semua dari transit (801 jadi 1.434) sedangkan timing malah turun dari 8 jadi 1 planet.

Panel (c) menunjukkan hal yang cukup mengejutkan: 2.066 planet atau 87,3% namanya berawalan Kepler, disusul K2 (94), HD (54), WASP (43), dan HATS (23). Karena itu ciri-ciri planet yang kita lihat di data ini, ukurannya kecil, periodenya pendek, jaraknya jauh, dan lebih menggambarkan kemampuan dan arah pengamatan misi Kepler daripada menggambarkan planet di alam semesta secara umum. Kepler cuma mengawasi satu petak langit dengan tingkat kepekaan tertentu, jadi hasilnya juga terbatas pada apa yang bisa dia lihat.

3.5 Sebaran Kolom Angka



Gambar 6. Sebaran kedelapan kolom angka; garis tegak menandai median, judulnya memuat jumlah terisi, jumlah kosong, dan nilai skewness

Tabel 5. Ringkasan statistik dan skewness tiap kolom angka

Kolom	n	Rata-rata	Std	Min	Median	Maks	Skew
massa_mj	299	2,073	3,632	0,0002	0,729	30,00	3,47
radius_rj	2.240	0,263	0,276	0,042	0,189	3,40	3,61
periode_hari	2.348	77,30	459,52	0,538	11,039	11.613	13,96
sumbu_semimayor_au	1.018	9,352	225,20	0,011	0,098	6.900	28,90
suhu_planet_k	104	1.232,3	534,78	131	1.292	2.508	-0,04
jarak_tahun_cahaya	2.291	2.470,1	1.707,3	4,2	2.320	27.000	4,99
massa_bintang_msun	2.101	0,955	0,239	0,080	0,950	3,21	0,79
suhu_bintang_k	2.340	5.488,8	669,08	2.559	5.636,5	10.500	-0,82


Berat planet cuma terisi di 299 planet, rentangnya dari 0,0002 sampai 30 MJ dengan median 0,729. Di skala log kelihatan ada dua kelompok, yaitu planet kecil di bawah 0,1 MJ (79 planet) dan planet raksasa di sekitar 1 MJ. Ukuran planet terisi di 2.240 baris dengan median 0,189 RJ atau sekitar dua kali ukuran Bumi. Sebanyak 1.846 planet (82%) berukuran 0,09 sampai 0,36 RJ, yang setara 1 sampai 4 kali ukuran Bumi. Ada juga puncak kecil kedua di sekitar 1 RJ dengan 138 planet berukuran di atas 0,8 RJ. Bentuk dua puncak dengan tumpukan besar di planet kecil ini cocok dengan hasil penelitian sebaran ukuran planet Kepler.

Periode orbit punya median 11,039 hari, dengan 1.102 planet (47%) selesai mengorbit kurang dari 10 hari dan cuma 67 planet yang butuh lebih dari setahun. Ini wajar karena transit lebih gampang menangkap planet yang dekat dengan bintangnya, sebab planetnya lebih sering lewat di depan bintang. Jarak planet ke bintangnya punya median 0,098 AU dan 515 planet (51% dari yang terisi)

jaraknya bahkan di bawah 0,1 AU. Kolom ini punya skewness paling tinggi yaitu 28,90, dan penyebabnya hampir seluruhnya cuma satu nilai yaitu 6.900 AU. Ini contoh bahwa satu data saja bisa merusak gambaran statistik satu kolom.


Suhu planet adalah kolom paling sedikit terisi (104 planet), tetapi justru paling merata sebarannya (skewness $-0,04$, median 1.292 K). Bentuk yang kelihatan bagus ini menipu, karena datanya sedikit dan isinya kebanyakan planet panas yang dekat bintang. Jarak dari Bumi punya median 2.320 tahun cahaya, khas target Kepler, dengan 28 planet di bawah 100 tahun cahaya dan 74 planet di atas 5.000 tahun cahaya. Berat bintang punya median 0,950 Msun dengan 1.504 bintang (72%) beratnya 0,8 sampai 1,2 Msun dan skewness 0,79, jadi ini kolom yang paling mendekati bentuk normal. Suhu bintang punya median 5.636,5 K dengan 1.407 bintang (60%) bersuhu 5.000 sampai 6.000 K, yaitu bintang tipe G seperti Matahari kita, dan miring ke kiri (skewness $-0,82$) karena ada 103 bintang katai M yang suhunya di bawah 4.000 K.

3.6 Hubungan Antarkolom



Gambar 7. Matriks korelasi Pearson (kiri) dan Spearman (kanan) antarkolom angka


Ada lima hubungan yang menonjol. Pertama, periode_hari dengan sumbu_semimayor_au korelasinya 0,95 (Pearson) dan 0,99 (Spearman) dari 999 pasang data. Ini memang sudah seharusnya karena keduanya terikat Hukum Kepler III, jadi kedua kolom ini isinya mirip dan kalau dipakai bersamaan nanti bisa bikin masalah di model. Kedua, massa_bintang_msun dengan suhu_bintang_k korelasinya 0,78 dan 0,86 dari 2.074 pasang, yang cocok dengan teori bahwa bintang lebih berat berarti lebih panas. Ketiga, radius_rj dengan suhu_planet_k korelasinya 0,80 dan 0,87, tapi cuma dihitung dari 97 pasang data jadi belum bisa terlalu dipercaya. Keempat, massa_mj dengan radius_rj punya selisih paling besar, yaitu 0,23 di Pearson tapi 0,72 di Spearman dari 176 pasang, tanda bahwa hubungannya searah tapi jelas tidak berbentuk garis lurus. Kelima, periode_hari dengan suhu_planet_k korelasinya $-0,32$ di Pearson tapi $-0,74$ di Spearman, yang artinya planet berperiode pendek memang lebih panas tapi hubungannya juga tidak lurus.



Gambar 8. Scatterplot hubungan antarkolom, diwarnai menurut kelompok metode: (a) jarak ke bintang vs periode, (b) ukuran vs berat planet, (c) ukuran vs periode, (d) suhu vs berat bintang induk

Panel (a) memperlihatkan titik-titiknya membentuk garis lurus rapi di skala log-log, yang merupakan bentuk grafik dari Hukum Kepler III. Transit menumpuk di periode pendek dan radial velocity di periode panjang. Waktu dicek dengan rumus, dari 745 planet yang punya periode, jarak ke bintang, dan berat bintang lengkap, median rasionya 1,006 dengan simpangan baku 0,145. Ini berarti isi datanya konsisten. Cuma ada dua planet yang keluar dari batas 0,5-2, yaitu Kepler-186c (0,429) dan XO-6b (3,466), yang kemungkinan ada angka salah di salah satu kolomnya dan perlu dicek lagi ke sumber aslinya.

Panel (b) menunjukkan dua pola berbeda. Untuk planet di bawah sekitar 0,3 MJ, semakin berat planetnya semakin besar juga ukurannya. Tapi di atas 0,3 MJ ukurannya mentok di sekitar 1 RJ walaupun beratnya nambah puluhan kali lipat. Ini ciri khas planet gas raksasa, dan inilah penyebab selisih Pearson dengan Spearman tadi [10]. Panel (c) memperlihatkan kelompok hot Jupiter, yaitu planet seukuran 1 RJ dengan periode di bawah 10 hari [18]. Yang juga menarik justru bagian yang kosong di kanan bawah: hampir tidak ada planet kecil dengan periode panjang. Ini bukan berarti planet begitu tidak ada, tapi karena sinyalnya terlalu lemah dan terlalu jarang untuk bisa ditangkap [2]. Panel (d) menunjukkan bintang induk planet transit mengikuti garis naik yang rapat, sedangkan bintang radial velocity yang beratnya di atas 1,3 Msun malah mendatar di suhu 4.000-5.600 K dan keluar dari pola. Kemungkinan besar itu bintang raksasa yang sudah tua.



Gambar 9. Sebaran jarak dari Bumi pada tiap metode deteksi (sumbu x skala log)

Gambar 8 merangkum semuanya dengan singkat. Jarak planet dari Bumi sangat tergantung metodenya. Imaging medianya 160 tahun cahaya dan radial velocity 208 tahun cahaya, karena dua

metode ini butuh bintang yang terang dan dekat. Timing medianya 1.790, transit 2.390, dan microlensing paling jauh yaitu 13.000 tahun cahaya karena survei microlensing diarahkan ke pusat galaksi yang bintangnya sangat padat [5]. Selisih sampai ratusan kali lipat ini menegaskan kesimpulan utama analisis ini: kolom metode_deteksi mempengaruhi hampir semua kolom lain, jadi data ini sebenarnya gabungan dari beberapa kelompok objek yang berbeda, bukan satu kelompok.

4 Kesimpulan

Setelah dianalisis dengan EDA, data 2.367 eksoplanet tahun 2014 dan 2016 ini sebenarnya rapi dari sisi bentuknya: tidak ada baris kembar, tidak ada nama planet yang dobel, semua kolom angka sudah bertipe benar, dan nama kolomnya konsisten. Isinya juga masuk akal secara fisika, terbukti dari median rasio Hukum Kepler III yang nilainya 1,006 dari 745 planet, dengan cuma dua baris yang menyimpang.

Tapi masih terdapat beberapa masalah. Diantaranya, nilai kosongnya sangat banyak dan polanya mengikuti kemampuan tiap metode serta kelengkapan tabel sumber tiap tahun, sampai-sampai cuma 3,3% baris yang terisi penuh. Kedua, sebaran hampir semua kolom planet sangat miring dan angkanya melompat jauh, jadi butuh skala log supaya bisa dibaca. Ketiga, ada 626 baris yang ditandai outlier oleh IQR, tapi setelah dicek satu per satu ternyata angkanya benar dan berasal dari jenis objek yang berbeda. Keempat, isinya sangat timpang dengan transit 94,4% dan Kepler 87,3%, jadi data ini lebih menggambarkan satu misi daripada planet pada umumnya. Temuan yang paling penting adalah kolom metode_deteksi ternyata jadi penjelas hampir semua ciri data, jadi setiap keputusan di tahap preprocessing harus mempertimbangkan kolom ini. Semua masalahnya dirangkum di Tabel 6.

Tabel 6. Rangkuman masalah data hasil EDA untuk tahap preprocessing

No	Masalah	Buktinya	Artinya untuk preprocessing
1	Nilai kosong banyak dan ada polanya	suhu_planet_k 95,6%; massa_mj 87,4%; sumbu_semimayor_au 57,0%; cuma 78 baris (3,3%) yang penuh	Hapus baris akan membuang 96,7% data; pengisian nilai harus melihat metode dan tahun
2	Sebaran sangat miring	Skewness 28,90 (jarak ke bintang), 13,96 (periode), 4,99 (jarak Bumi), 3,61 (ukuran), 3,47 (berat)	Perlu diubah ke skala log sebelum dipakai untuk model
3	Outlier ternyata benar adanya	626 baris ditandai IQR; turun jauh di skala log; 6 objek di atas 13 MJ kemungkinan katai coklat	Outlier jangan dihapus otomatis; harus dilihat dulu artinya
4	Jumlah kategori tidak seimbang	Transit 94,4%; Kepler 87,3%; tiga metode kecil totalnya cuma 27 planet	Statistiknya mewakili planet transit Kepler, bukan planet pada umumnya
5	Ada kolom yang isinya mirip	periode_hari dan sumbu_semimayor_au korelasinya 0,99 (Spearman)	Salah satu bisa dibuang atau digabung jadi kolom baru
6	Ada nilai yang janggal	Kepler-186c (rasio 0,429) dan XO-6b (3,466) tidak cocok dengan Hukum Kepler III	Dua baris ini perlu dicek ulang ke sumber aslinya
7	Ada kolom yang kurang berguna	nama beda semua tiap baris; tahun_penemuan cuma 2 nilai; satuan berat planet dan bintang beda	nama diubah jadi kolom awalan katalog; tahun_penemuan dijadikan kategori