

Praproses Data Harga Rumah pada Dataset House Prices menggunakan Imputasi KNN, Encoding, dan PCA

Maria Putu Evelyne Corena Puryatma

5054251011

ABSTRAK

Penelitian ini bertujuan untuk melakukan praproses data pada dataset House Prices – Advanced Regression Techniques dari Kaggle agar data siap digunakan untuk analisis dan pemodelan machine learning. Data yang digunakan adalah file train.csv yang berisi 1460 data penjualan rumah dengan 81 kolom, dengan SalePrice sebagai target. Tahapan yang dilakukan meliputi eksplorasi data, pembersihan data, deteksi dan penanganan outlier, transformasi data, serta reduksi dimensi. Hasil eksplorasi menunjukkan bahwa dari 7829 sel kosong, 96,4% merupakan NA struktural yang berarti fasilitas rumah tersebut tidak ada, sehingga hanya 278 sel yang benar-benar hilang. Nilai kosong ditangani dengan membuang 5 kolom yang kosong lebih dari 50%, mengisi NA struktural dengan kategori “Tidak Ada”, dan mengisi LotFrontage menggunakan KNN yang memiliki galat terkecil (MAE 11,28 ft). Outlier dipilah berdasarkan sifatnya: 2 transaksi anomali dihapus dan LotArea disesuaikan dengan capping persentil 99. Transformasi dilakukan dengan log1p, encoding ordinal dan one-hot, serta standarisasi. Pembuangan fitur hampir konstan dan fitur berkorelasi tinggi menghasilkan 135 fitur, lalu PCA dengan 95% varians memadatkannya menjadi 51 komponen. Komponen utama pertama (PC1) merepresentasikan kualitas dan ukuran rumah dengan korelasi 0,906 terhadap log harga. Hasil akhir berupa data bersih berukuran 1458×76 dan matriks fitur siap model berukuran 1458×135 .

Kata kunci: Praproses data, House Prices, nilai hilang, outlier, Principal Component Analysis (PCA).

1. Latar Belakang

Harga rumah dipengaruhi oleh banyak faktor, mulai dari luas bangunan, kualitas material, tahun dibangun, sampai lokasi. Salah satu dataset yang populer adalah data perumahan kota Ames, Iowa, yang dikumpulkan oleh De Cock sebagai alternatif dari dataset Boston Housing yang lebih sederhana. Dataset ini kemudian digunakan dalam kompetisi Kaggle House Prices – Advanced Regression Techniques.

Data yang diperoleh dari dunia nyata jarang langsung siap digunakan. Data sering kali memiliki nilai yang hilang, nilai ekstrem (outlier), penulisan yang tidak konsisten, dan skala fitur yang berbeda-beda. Jika masalah ini dibiarkan, hasil analisis dan model yang dibangun bisa menjadi tidak akurat. Karena itu diperlukan tahap praproses data yang meliputi pembersihan, integrasi, transformasi, dan reduksi data.

Sebelum melakukan praproses, data perlu dipahami terlebih dahulu melalui Exploratory Data Analysis (EDA). EDA membantu melihat bentuk sebaran data, hubungan antar variabel, dan kejanggalan pada data dengan bantuan statistik deskriptif dan visualisasi. Hasil EDA inilah yang menjadi dasar dalam menentukan cara menangani nilai kosong dan outlier, sehingga keputusan yang diambil tidak asal-asalan.

Untuk nilai yang hilang, salah satu metode yang dapat digunakan adalah imputasi k-Nearest Neighbors (KNN), yaitu mengisi nilai kosong berdasarkan data lain yang paling mirip. Sementara itu, untuk data dengan jumlah fitur yang banyak, Principal Component Analysis (PCA) dapat digunakan untuk merangkum fitur-fitur tersebut menjadi sejumlah kecil komponen baru tanpa kehilangan banyak informasi.

Berdasarkan hal tersebut, makalah ini membahas penerapan tahapan praproses data pada dataset House Prices sesuai dengan Tugas Praktikum 2: Praproses Data. Tahapan yang dilakukan meliputi pembersihan data, penanganan outlier, transformasi (normalisasi dan encoding), serta reduksi dimensi menggunakan analisis korelasi dan PCA. Seluruh proses dikerjakan menggunakan bahasa Python dengan library pandas, scikit-learn, matplotlib, dan seaborn. Selain menjelaskan langkah yang dilakukan, makalah ini juga menyajikan temuan-temuan penting yang didapat selama praproses beserta alasan di balik setiap keputusan.

2. Metodologi Penelitian

Metodologi yang digunakan dalam praproses dataset House Prices meliputi tahapan seperti pada Gambar 1 di bawah ini:



Gambar 1. Tahapan Metodologi Penelitian

1. Pengumpulan Data

Data diperoleh dari halaman kompetisi Kaggle House Prices – Advanced Regression Techniques. File yang digunakan hanya train.csv yang berisi 1460 baris dan 81 kolom. Setiap baris adalah satu transaksi penjualan rumah di Ames, Iowa, pada tahun 2006–2010, dan kolom SalePrice (harga jual dalam USD) dijadikan sebagai target.

2. Eksplorasi Data (EDA)

Struktur data diperiksa dengan `.head()`, `.shape`, dan `.info()`, lalu dihitung statistik deskriptifnya. Distribusi setiap fitur dilihat menggunakan histogram, line chart, dan box plot. Hubungan fitur numerik dengan harga diukur dengan korelasi Pearson dan Spearman, sedangkan untuk fitur kategorik digunakan rasio korelasi (eta, η) yang bernilai 0 sampai 1.

3. Pembersihan Data

Jumlah nilai kosong pada setiap kolom dihitung, lalu kolom dengan nilai kosong lebih dari 50% dihapus sesuai ketentuan tugas. Nilai kosong sisanya dipisahkan antara NA struktural (fasilitas tidak ada) dan nilai yang benar-benar hilang. NA struktural diisi kategori “Tidak Ada”, sedangkan nilai yang hilang diimputasi. Pada tahap ini juga diperiksa data yang tidak konsisten, seperti salah penulisan label dan nilai yang tidak logis.

4. Deteksi dan Penanganan Outlier

Outlier dideteksi dengan box plot menggunakan aturan Tukey, yaitu nilai di bawah $Q1 - 1,5 \times IQR$ atau di atas $Q3 + 1,5 \times IQR$. Setiap outlier kemudian diperiksa sifatnya untuk menentukan apakah dihapus, disesuaikan (capping), atau dibiarkan.

5. Transformasi Data

Target diubah menggunakan `log1p`, yaitu $\log(1 + x)$. Fitur kategorik ordinal diubah menjadi angka berurutan, fitur nominal diubah dengan one-hot encoding, fitur kontinu yang miring diberi `log1p`, lalu seluruh kolom numerik distandarisasi dengan `StandardScaler`.

6. Reduksi Dimensi

Fitur yang hampir konstan dibuang, kemudian dilakukan analisis korelasi untuk membuang salah satu dari pasangan fitur yang berkorelasi tinggi ($|r| > 0,8$). Terakhir, PCA diterapkan untuk mengurangi dimensi data dengan mempertahankan 95% varians.

3. Hasil dan Pembahasan

Bagian ini membahas hasil dari setiap tahapan praproses beserta temuan-temuan penting yang didapat selama pengerjaan.

3.1 Gambaran Umum Dataset

Tabel 1. Beberapa baris pertama dataframe (sebagian kolom)

	Id	MSSubClass	MSZoning	LotArea	OverallQual	YearBuilt	GrLivArea	GarageCars	SalePrice
0	1	60	RL	8450	7	2003	1710	2	208500
1	2	20	RL	9600	6	1976	1262	2	181500
2	3	60	RL	11250	7	2001	1786	2	223500
3	4	70	RL	9550	7	1915	1717	3	140000

	Id	MSSubClass	MSZoning	LotArea	OverallQual	YearBuilt	GrLivArea	GarageCars	SalePrice
4	5	60	RL	14260	8	2000	2198	3	250000

Tabel 1 menampilkan lima baris pertama dataset untuk beberapa kolom saja, karena jumlah kolomnya terlalu banyak untuk ditampilkan semuanya. Dataset terdiri dari 1460 baris dan 81 kolom, yaitu 43 kolom bertipe object, 35 int64, dan 3 float64. Tidak ditemukan baris duplikat dan kolom Id bernilai unik.


Jika hanya melihat tipe data, di luar Id dan SalePrice terdapat 36 fitur bertipe angka. Namun setelah diperiksa maknanya, fitur-fitur tersebut terdiri dari 33 fitur numerik (19 kontinu, 9 diskrit, dan 5 waktu) dan 46 fitur kategorik (15 ordinal teks, 28 nominal teks, dan 3 kategori yang disimpan sebagai angka). Ada tiga hal yang perlu diperhatikan. Pertama, MSSubClass berupa angka (20, 60, 120, ...) tetapi sebenarnya kode tipe bangunan, sehingga harus diperlakukan sebagai kategori nominal. Kedua, OverallQual dan OverallCond adalah skala 1–10 yang berurutan (ordinal). Ketiga, LotFrontage, MasVnrArea, dan GarageYrBlt bertipe float hanya karena ada nilai kosong, padahal semua nilainya bulat.

3.2 Statistik Deskriptif dan Distribusi Target

Tabel 2. Ringkasan statistik deskriptif beberapa fitur numerik

	SalePrice	GrLivArea	LotArea	TotalBsmtSF	OverallQual	YearBuilt
count	1460	1460	1460	1460	1460	1460
mean	180.921,20	1515,46	10.516,83	1057,43	6,10	1971,27
std	79.442,50	525,48	9981,26	438,71	1,38	30,20
min	34.900,00	334,00	1300,00	0,00	1,00	1872,00
25%	129.975,00	1129,50	7553,50	795,75	5,00	1954,00
50%	163.000,00	1464,00	9478,50	991,50	6,00	1973,00
75%	214.000,00	1776,75	11.601,50	1298,25	7,00	2000,00
max	755.000,00	5642,00	215.245,00	6110,00	10,00	2010,00

Tabel 2 menyajikan ringkasan statistik untuk target dan beberapa fitur numerik utama. SalePrice memiliki mean 180.921 USD yang lebih besar dari median 163.000 USD, dengan rentang 34.900 – 755.000 USD. LotArea juga menunjukkan hal yang mencolok, yaitu nilai maksimum 215.245 sqft atau sekitar 23 kali mediannya.



Gambar 2. Distribusi SalePrice sebelum dan sesudah log1p, beserta Q-Q plot

Gambar 2 menunjukkan bahwa sebaran SalePrice miring ke kanan dengan skewness 1,88. Terdapat 61 rumah di atas batas atas IQR (340.038 USD), tetapi 58 di antaranya memiliki kualitas 8–10, sehingga rumah-rumah ini adalah rumah mahal yang sah, bukan kesalahan input. Setelah ditransformasi dengan log1p, skewness turun menjadi 0,12 dan titik pada Q-Q plot hampir lurus mengikuti garis normal. Karena itu, target digunakan dalam bentuk log.


Selain itu, ditemukan banyak fitur yang hampir selalu bernilai 0, seperti PoolArea (99,5%), 3SsnPorch (98,4%), LowQualFinSF (98,2%), MiscVal (96,4%), dan ScreenPorch (92,1%). Fitur seperti ini lebih mirip penanda ada atau tidaknya fasilitas daripada ukuran. Beberapa fitur kategorik juga hampir konstan, misalnya Utilities (hanya 1 rumah yang berbeda), Street (99,6%), dan Condition2 (99,0%).

3.3 Hubungan Fitur dengan Harga

Tabel 3. Korelasi Pearson dan Spearman beberapa fitur numerik terhadap SalePrice


Fitur	Pearson (r)	Spearman (ρ)
OverallQual	0,791	0,810
GrLivArea	0,709	0,731
GarageCars	0,640	0,691
GarageArea	0,623	0,649
TotalBsmstSF	0,614	0,603
1stFlrSF	0,606	0,575
YearBuilt	0,523	0,653
LotArea	0,264	0,456

Tabel 3 menunjukkan bahwa fitur numerik yang paling berhubungan dengan harga adalah OverallQual ($r = 0,79$), GrLivArea (0,71), GarageCars (0,64), GarageArea (0,62), serta TotalBsmstSF dan 1stFlrSF (0,61). Menariknya, YearBuilt memiliki Spearman 0,65 yang lebih besar dari Pearson 0,52. Artinya hubungan YearBuilt dengan harga memang ada, tetapi tidak linear: harga melonjak pada rumah yang dibangun setelah sekitar tahun 1990. Hal serupa terjadi pada LotArea ($r = 0,26$ tetapi $\rho = 0,46$), di mana hubungannya tertutup oleh beberapa kavling yang sangat luas.



Gambar 3. Matriks korelasi Pearson menggunakan heatmap

Gambar 3 menampilkan matriks korelasi Pearson dalam bentuk heatmap. Selain hubungan dengan harga, heatmap ini juga memperlihatkan pasangan fitur yang saling berkorelasi tinggi, yaitu GarageArea–GarageCars (0,88), GarageYrBlt–YearBuilt (0,83), TotRmsAbvGrd–GrLivArea (0,83), dan 1stFlrSF–TotalBsmntSF (0,82). Setiap pasangan tersebut pada dasarnya mengukur hal yang sama, sehingga menjadi kandidat untuk dibuang salah satunya pada tahap reduksi dimensi.



Gambar 4. Sebaran harga per kategori pada OverallQual, Neighborhood, dan ExterQual

Untuk fitur kategorik, hubungan terkuat dengan harga (eta) dimiliki oleh OverallQual (0,83), Neighborhood (0,74), ExterQual (0,69), BsmntQual (0,68), dan KitchenQual (0,68). Gambar 4 memperlihatkan bahwa lokasi berpengaruh besar: median harga termurah ada di MeadowV (88.000 USD) dan termahal di NridgHt (315.000 USD), atau sekitar 3,6 kali lipat. Pada fitur kualitas, median harga naik berurutan dari Fa < TA < Gd < Ex. Pola ini menjadi dasar penggunaan encoding ordinal untuk fitur kualitas. Selain itu, kategori “tidak ada” (tanpa garasi,

basement, atau perapian) selalu termasuk kelompok yang paling murah, sehingga “tidak ada” juga merupakan informasi.

Ada satu temuan yang awalnya terlihat aneh, yaitu rumah mahal justru menumpuk di OverallCond = 5 (rata-rata). Setelah diperiksa, rumah dengan kondisi 5 umumnya adalah rumah baru (median dibangun tahun 1998), sedangkan kondisi 6–8 kebanyakan rumah tua. Jadi nilai OverallCond yang tinggi belum tentu berarti harga yang lebih mahal. Sementara itu, MoSold dan YrSold hampir tidak berpengaruh terhadap harga.

3.4 Penanganan Nilai Kosong


Pemeriksaan awal menunjukkan ada 19 kolom dengan total 7829 sel kosong. Namun setelah dicocokkan dengan dokumentasi dataset, 7551 sel (96,4%) merupakan NA struktural, yaitu nilai kosong yang berarti fasilitasnya memang tidak ada. Hal ini dibuktikan dari kolom pasangannya: PoolQC kosong tepat di 1453 rumah dengan PoolArea = 0, FireplaceQu kosong tepat di 690 rumah dengan Fireplaces = 0, lima kolom garasi kosong di 81 rumah yang sama dengan GarageArea = 0, dan lima kolom basement kosong di 37 rumah dengan TotalBsmtSF = 0. Rincian nilai kosong dan penanganannya dapat dilihat pada Tabel 4.

Tabel 4. Nilai kosong per kolom dan penanganannya

Kolom	Jumlah kosong	Jenis	Penanganan
PoolQC	1453 (99,5%)	Struktural	Dibuang (> 50%)
MiscFeature	1406 (96,3%)	Struktural	Dibuang (> 50%)
Alley	1369 (93,8%)	Struktural	Dibuang (> 50%)
Fence	1179 (80,8%)	Struktural	Dibuang (> 50%)
MasVnrType	872 (59,7%)	864 “None” + 8 hilang	Dibuang (> 50%)
FireplaceQu	690 (47,3%)	Struktural	Diisi “Tidak Ada”
LotFrontage	259 (17,7%)	Hilang sebenarnya	Imputasi KNN (k = 5)
5 kolom garasi	81 (5,5%)	Struktural	“Tidak Ada”; GarageYrBltn = YearBuilt
BsmtQual, BsmtCond, BsmtFinType1	37 (2,5%)	Struktural	Diisi “Tidak Ada”
BsmtExposure, BsmtFinType2	38 (2,6%)	37 struktural + 1 hilang	“Tidak Ada”; No (Id 949), Rec (Id 333)
MasVnrArea	8 (0,6%)	Hilang sebenarnya	Diisi 0
Electrical	1 (0,1%)	Hilang sebenarnya	Diisi SBrkr

Dari Tabel 4 terlihat bahwa nilai yang benar-benar hilang hanya 278 sel. Ada juga jebakan dari pandas, yaitu teks “None” pada MasVnrType otomatis dibaca sebagai NaN. Akibatnya kolom ini tercatat 59,7% kosong, padahal 864 dari 872 sel

tersebut adalah kategori “tanpa pelapis batu” dan hanya 8 yang benar-benar kosong. Meskipun begitu, kolom ini tetap dibuang agar sesuai dengan aturan tugas, dan informasinya sebagian besar sudah terwakili oleh MasVnrArea.



Gambar 5. Nilai kosong per kolom (biru = struktural, merah = hilang sebenarnya) dan pola kosong per baris

Gambar 5 memperlihatkan bahwa kolom garasi kosong di baris yang sama, begitu juga kolom basement. Artinya penyebab kosongnya hanya satu, yaitu fasilitas tersebut tidak ada. Untuk kolom yang dibuang, informasinya tidak terlalu hilang karena masih ada kolom pengganti seperti PoolArea, MiscVal, dan MasVnrArea. Alley dan Fence memang tidak punya pengganti, tetapi hubungannya dengan harga lemah (η 0,14 dan 0,19).

Nilai kosong pada LotFrontage ternyata tidak acak: 52% terjadi pada kavling CulDSac dibanding 13% pada kavling Inside, bahkan di lingkungan ClearCr mencapai 54%. Karena itu, mengisinya dengan median global kurang tepat. Untuk memilih metode imputasi, 20% nilai asli LotFrontage disembunyikan, diisi dengan beberapa metode, lalu dibandingkan dengan nilai sebenarnya. Proses ini diulang 20 kali dan hasilnya ditampilkan pada Tabel 5.

Tabel 5. Perbandingan galat metode imputasi LotFrontage (20 kali pengulangan)

Metode	Rata-rata galat (MAE)
KNN (log LotArea + luas bangunan)	11,28 ft
KNN (log LotArea saja)	12,04 ft
Median per Neighborhood	12,78 ft
Median global	16,42 ft


Berdasarkan Tabel 5, KNN dengan fitur log LotArea dan luas bangunan memberikan galat paling kecil, sehingga metode ini yang dipilih. Nilai hilang lainnya diisi berdasarkan logika dari data. Electrical (Id 1380, dibangun 2006) diisi SBrkr karena semua rumah yang dibangun sejak 2000 memakai SBrkr, sedangkan BsmtFinType2 (Id 333) diisi Rec, bukan modus umum Unf, karena

rumah ini memiliki area basement jadi seluas 479 sqft. Setelah semua langkah ini, jumlah sel kosong turun dari 7829 menjadi 1550 (setelah membuang kolom), 270 (setelah mengisi NA struktural), dan akhirnya 0.

Selain nilai kosong, ditemukan juga beberapa data yang tidak konsisten. Label pada Exterior2nd ditulis berbeda dengan Exterior1st (“Brk Cmn”, “CmentBd”, “Wd Shng”), sehingga diseragamkan menjadi “BrkComm”, “CemntBd”, dan “WdShing” pada 105 baris. Tanpa perbaikan ini, one-hot encoding akan membuat dua kolom untuk material yang sama. MasVnrArea bernilai 1 sqft padahal tipenya “None” (Id 774 dan 1231), sehingga diubah menjadi 0. Id 524 tercatat direnovasi tahun 2008 padahal terjual tahun 2007, dan ternyata rumah ini juga termasuk anomali harga. Sementara itu, pengecekan penjumlahan luas (misalnya $\text{TotalBsmtSF} = \text{BsmtFinSF1} + \text{BsmtFinSF2} + \text{BsmtUnfSF}$) lolos di semua baris.


3.5 Deteksi dan Penanganan Outlier

Hasil box plot menunjukkan jumlah outlier yang sangat banyak, tetapi angka ini tidak bisa langsung dipercaya. Seperti terlihat pada Gambar 6, outlier dapat dibagi menjadi tiga jenis. Pertama, artefak $\text{IQR} = 0$ pada 9 fitur yang hampir selalu bernilai 0, misalnya EnclosedPorch dengan 208 “outlier”. Karena $Q1 = Q3$, semua nilai selain 0 otomatis dianggap outlier. Kedua, nilai langka pada fitur diskrit atau kode seperti OverallCond, MSSubClass, dan BedroomAbvGr. Ketiga, nilai ekstrem kontinu yang memang perlu diperiksa, yaitu MasVnrArea, LotFrontage, LotArea, TotalBsmtSF, GrLivArea, dan SalePrice.




Gambar 6. Jumlah outlier IQR per fitur, dibedakan menurut sifatnya

Terdapat 387 baris yang memiliki minimal satu outlier kontinu. Jika semuanya dihapus, sekitar 26% data akan hilang. Oleh karena itu, setiap outlier diperiksa terlebih dahulu sebelum diputuskan cara penanganannya.



Gambar 7. Dua anomali pada GrLivArea vs SalePrice (kiri) dan harga per sqft per OverallQual (kanan)

Gambar 7 memperlihatkan dua rumah yang jelas menyimpang, yaitu Id 524 dan 1299. Keduanya sangat besar (4676 dan 5642 sqft) dengan kualitas tertinggi (10), tetapi harganya hanya 184.750 dan 160.000 USD. Harga per sqft-nya hanya 40 dan 28 USD, padahal median rumah berkualitas 10 adalah 174 USD. Keduanya juga dijual dengan status Partial (rumah belum selesai dibangun), sehingga bukan penjualan normal. Kedua baris ini dihapus, dan korelasi GrLivArea dengan harga naik dari 0,709 menjadi 0,735. Rumah murah lain seperti Id 31 dan 496 tidak dihapus karena kualitasnya hanya 4, sedangkan rumah besar Id 692 dan 1183 dipertahankan karena harganya sepadan (755.000 dan 745.000 USD).



Gambar 8. Efek capping LotArea pada box plot (kiri) dan hubungannya dengan SalePrice (kanan)

Untuk fitur kontinu lainnya, dicoba capping di persentil 99 lalu dilihat apakah korelasinya dengan harga membaik. Hasilnya, hanya LotArea yang jelas membaik. Sebanyak 15 kavling dipotong ke 35.403 sqft, skewness turun dari 12,57 ke 2,20, dan korelasi dengan harga naik dari 0,268 ke 0,401 (Gambar 8). Kavling raksasa tersebut sebenarnya nyata (daerah pinggiran seperti Timber dan ClearCr), tetapi harganya tidak naik sebanding dengan luasnya. Sebaliknya, korelasi GrLivArea justru turun ($-0,016$) jika di-capping, yang berarti nilai

ekstremnya informatif. Outlier lain seperti rumah mahal pada SalePrice, fitur yang hampir selalu 0, dan nilai langka pada fitur diskrit dibiarkan karena merupakan informasi nyata.

Hasil pembersihan disimpan sebagai train_clean.csv dengan ukuran 1458×76 tanpa sel kosong. Sebanyak 25 dari 37 fitur numerik hampir tidak berubah (mean dan standar deviasi bergeser kurang dari 0,5%). Perubahan besar hanya terjadi pada fitur yang memang ditangani, misalnya standar deviasi LotArea turun 51% karena capping. Hal ini menunjukkan bahwa pembersihan berhasil menghilangkan masalah tanpa mengubah karakter data.

3.6 Transformasi Data

Setelah data bersih, target dipisahkan menjadi $y = \log_{1p}(\text{SalePrice})$ dan kolom Id dibuang karena hanya nomor urut. Encoding dilakukan secara campuran. Sebanyak 14 fitur ordinal diubah menjadi angka berurutan (Tidak Ada = 0, Po = 1, Fa = 2, TA = 3, Gd = 4, Ex = 5), karena urutan kualitas berhubungan dengan harga dan akan hilang jika memakai one-hot. Sementara itu, 25 fitur nominal (termasuk MSSubClass) diubah dengan one-hot encoding menjadi 183 kolom, sehingga total fitur menjadi 232 kolom. Jika semua fitur kategorik di-one-hot, jumlahnya akan menjadi 294 kolom.


Transformasi $\log_{1p}$ juga diterapkan pada 16 fitur kontinu yang miring, tetapi hanya jika skewness-nya benar-benar turun. BsmtUnfSF tidak di-log karena skewness-nya justru berubah dari 0,92 menjadi -2,18. Selanjutnya, 49 kolom numerik distandarisasi dengan StandardScaler sehingga memiliki mean 0 dan standar deviasi 1. StandardScaler dipilih dibanding Min-Max karena hasil Min-Max sangat ditentukan oleh satu nilai terkecil dan terbesar, sedangkan PCA membutuhkan varians yang setara. Kolom dummy dibiarkan bernilai 0/1, karena jika distandarisasi, dummy untuk kategori yang hanya dimiliki 1% rumah akan bernilai sekitar 10 dan mendominasi PCA.

3.7 Reduksi Dimensi

Reduksi dimensi dilakukan dalam tiga langkah. Pertama, 69 kolom yang hampir konstan (satu nilai mencakup lebih dari 99% baris) dibuang, seperti Street, Utilities, PoolArea, dan dummy kategori langka, sehingga kolom berkurang dari 232 menjadi 163. Kedua, dari analisis korelasi ditemukan 29 pasangan fitur dengan $|r| > 0,8$ dan 28 kolom dibuang. Dari setiap pasangan dipertahankan fitur yang korelasinya dengan log harga lebih kuat, sehingga tersisa 135 kolom.

Menariknya, redundansi paling banyak justru berasal dari hasil one-hot, bukan dari data aslinya. Contohnya CentralAir_Y dan CentralAir_N ($r = -1$), SaleType_New dan SaleCondition_Partial ($r = 0,99$) karena rumah baru biasanya dijual sebelum selesai dibangun, serta MSSubClass_90 yang sama persis dengan

BldgType_Duplex ($r = 1,00$). Sisanya adalah ukuran fisik yang sama, seperti GarageArea/GarageCars dan TotRmsAbvGrd/GrLivArea.



Gambar 9. Scree plot PCA (kiri) dan data pada dua komponen utama pertama, diwarnai log harga (kanan)

Langkah ketiga adalah PCA. Seperti terlihat pada Gambar 9, untuk menjelaskan 80% varians dibutuhkan 24 komponen, 90% membutuhkan 37 komponen, dan 95% membutuhkan 51 komponen. Dengan batas 95%, 135 fitur dipadatkan menjadi 51 komponen (berkurang 62%). Komponen pertama (PC1) menjelaskan 19,4% varians dan dapat diartikan sebagai sumbu “kualitas dan ukuran rumah”, dengan kontributor terbesar OverallQual, ExterQual, YearBuilt, BsmtQual, KitchenQual, dan GarageCars. Korelasi PC1 dengan log harga mencapai 0,906, padahal PCA sama sekali tidak melihat harga. Hal ini juga terlihat pada Gambar 9 bagian kanan, di mana warna titik makin gelap (harga makin mahal) saat nilai PC1 makin besar. Komponen kedua (PC2, 7,0%) membedakan rumah bertingkat dari rumah satu lantai dengan basement jadi.

3.8 Ringkasan Dataset Akhir

Tabel 6. Ukuran data dan jumlah sel kosong di setiap tahap

Tahap	Baris × kolom	Sel kosong
Data mentah	1460 × 81	7829
Buang kolom kosong > 50%	1460 × 76	1550
Isi NA struktural	1460 × 76	270
Imputasi nilai hilang	1460 × 76	0
Hapus 2 anomali	1458 × 76	0
Capping LotArea (= train_clean.csv)	1458 × 76	0
Pisah Id dan target	1458 × 74	0
Encoding	1458 × 232	0
Buang fitur hampir konstan	1458 × 163	0
Buang fitur berkorelasi tinggi	1458 × 135	0
PCA 95% varians	1458 × 51	0

Tabel 6 merangkum perubahan ukuran data di setiap tahap. Data mentah berukuran 1460×81 dengan 7829 sel kosong berhasil menjadi `train_clean.csv` berukuran 1458×76 tanpa sel kosong. Setelah transformasi dan reduksi, data yang siap dipakai untuk model berukuran 1458×135 (41 kolom numerik terstandarisasi dan 94 dummy 0/1) dengan target $y = \log_{1p}(\text{SalePrice})$, atau 1458×51 jika menggunakan PCA.

4. Kesimpulan

Dapat disimpulkan bahwa tahapan praproses yang dilakukan berhasil mengubah dataset House Prices menjadi data yang bersih dan siap digunakan untuk pemodelan. Temuan terpenting adalah sebagian besar nilai kosong pada dataset ini berarti “tidak ada fasilitas”, di mana hanya 278 dari 7829 sel yang benar-benar hilang. Outlier juga perlu dipilah sifatnya terlebih dahulu: hanya 2 transaksi tidak wajar yang dihapus, LotArea disesuaikan, dan sisanya dipertahankan karena merupakan informasi nyata. Keputusan imputasi dan capping diuji dengan angka (galat imputasi dan perubahan korelasi), bukan sekadar tebakan. Skala kualitas lebih cocok di-encode secara ordinal, sedangkan fitur nominal di-one-hot, dan PCA menunjukkan adanya satu sumbu utama (kualitas dan ukuran rumah) yang sangat berkaitan dengan harga.

Penelitian ini masih memiliki beberapa keterbatasan. `MasVnrType` dibuang karena aturan 50% padahal nilai yang benar-benar kosong hanya 0,5%, keputusan capping hanya didasarkan pada perubahan korelasi Pearson, dan imputasi KNN membuat sebaran `LotFrontage` sedikit lebih sempit dari aslinya. Selain itu, belum dilakukan pemodelan, sehingga pengaruh praproses ini terhadap akurasi model belum diuji. Penelitian selanjutnya dapat membangun model regresi untuk membandingkan hasil prediksi dengan dan tanpa tahapan praproses ini.