Penanganan Class Imbalance pada Deteksi Penipuan Kartu Kredit menggunakan XGBoost

Maria Putu Evelyne Corena Puryatma
5054251011

Abstrak

Eksperimen ini membuat model klasifikasi untuk mendeteksi transaksi fraud pada dataset Credit Card Fraud Detection dari Kaggle. Datanya sangat tidak seimbang, karena dari 284.807 transaksi hanya 492 (0,173%) yang fraud. Model yang dipakai adalah XGBoost, lalu hasilnya dibandingkan antara tanpa resampling, dengan undersampling, dan dengan SMOTE. Model tanpa resampling mendapat F1-score paling tinggi (0,863). Undersampling memang menaikkan recall, tetapi banyak transaksi normal jadi salah dianggap fraud, sedangkan SMOTE berada di antara keduanya. Dari eksperimen ini terlihat bahwa accuracy saja tidak cukup untuk data yang tidak seimbang, dan resampling tidak selalu membuat model lebih bagus.

Kata kunci: fraud, class imbalance, XGBoost, SMOTE, undersampling.

1. Latar Belakang

Transaksi menggunakan kartu kredit semakin banyak dilakukan, sehingga risiko penipuan (fraud) juga semakin besar. Transaksi fraud merugikan nasabah maupun bank, sehingga bank perlu cara untuk mendeteksi transaksi yang mencurigakan secara otomatis. Salah satu caranya adalah dengan membuat model machine learning yang dapat mengklasifikasikan sebuah transaksi menjadi transaksi normal atau fraud.

Masalahnya, jumlah transaksi fraud jauh lebih sedikit dibandingkan transaksi normal. Kondisi ini disebut class imbalance. Jika model dilatih langsung dengan data seperti ini, model cenderung lebih sering menebak kelas mayoritas (normal). Nilai accuracy model memang akan terlihat tinggi, tetapi banyak transaksi fraud yang bisa saja tidak terdeteksi. Oleh karena itu, diperlukan teknik penanganan class imbalance seperti undersampling atau oversampling (SMOTE), serta metrik evaluasi yang sesuai.

Dalam penelitian ini, digunakan ensemble method jenis gradient boosting, yaitu XGBoost. Ensemble method menggabungkan banyak pohon keputusan (decision tree), sehingga hasilnya biasanya lebih baik dibanding hanya memakai satu pohon. Model kemudian dibandingkan dalam tiga kondisi, yaitu tanpa resampling, dengan undersampling, dan dengan SMOTE.

1.1 Permasalahan yang Dibahas

Permasalahan dalam studi kasus ini adalah memprediksi apakah sebuah transaksi kartu kredit termasuk fraud (Class = 1) atau normal (Class = 0). Permasalahan ini termasuk klasifikasi biner dengan data yang sangat tidak seimbang. Rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana distribusi kelas pada dataset Credit Card Fraud Detection?
2. Bagaimana pengaruh teknik penanganan class imbalance (undersampling dan SMOTE) terhadap performa model XGBoost?
3. Metrik apa yang tepat untuk menilai model pada data yang tidak seimbang, dan mengapa accuracy saja tidak cukup?

2. Metodologi Penelitian

Penelitian ini dilakukan menggunakan Python dengan library pandas, numpy, matplotlib, seaborn, scikit-learn, imbalanced-learn, dan xgboost. Tahapan yang dilakukan adalah sebagai berikut.

1. **Pengumpulan Data**
   Data diambil dari Kaggle (Credit Card Fraud Detection, file creditcard.csv). Dataset berisi 284.807 baris dan 31 kolom. Kolom target adalah Class, yaitu transaksi normal (0) atau fraud (1).
2. **Pengecekan Data**
   Data diperiksa ukuran, tipe data, statistik deskriptif, nilai kosong, dan jumlah baris duplikat menggunakan .head(), .shape, .info(), dan .describe().
3. **Analisis Distribusi Kelas**
   Jumlah dan persentase setiap kelas pada kolom Class dihitung, lalu divisualisasikan dengan diagram batang.
4. **Pembagian Data**
   Data dipisahkan menjadi fitur (X) dan target (y), lalu dibagi menjadi data latih dan data uji dengan perbandingan 80:20 menggunakan stratify=y dan random_state=42.
5. **Penanganan Class Imbalance**
   Dua teknik diterapkan hanya pada data latih, yaitu random undersampling dan oversampling SMOTE. Data uji tidak diubah dan tetap memakai distribusi asli.
6. **Pembangunan Model**
   Model XGBoost (XGBClassifier) dilatih dengan tuning GridSearchCV (Stratified K-Fold 5 bagian, scoring F1). Parameter terbaik dipakai untuk ketiga model agar perbandingannya adil.
7. **Evaluasi Model**
   Model dievaluasi pada data uji menggunakan accuracy, precision, recall, F1-score, dan AUC-ROC untuk kelas fraud. Hasil prediksi juga dilihat dengan confusion matrix dan

kurva ROC.

3. Hasil dan Pembahasan

Melalui pengecekan data, penanganan class imbalance, pemodelan, dan evaluasi, diperoleh beberapa temuan penting. Hasil tersebut dijelaskan pada subbab berikut.

3.1 Data yang Digunakan

Dataset berisi 284.807 baris dan 31 kolom. Fitur V1 sampai V28 merupakan hasil transformasi PCA, sehingga nama dan arti aslinya tidak diketahui karena dirahasiakan untuk menjaga privasi nasabah.

Atribut	Jenis	Tipe data	Keterangan
Time	Numerik	float64	Selisih waktu (detik) antara transaksi tersebut dengan transaksi pertama dalam dataset
V1 - V28	Numerik	float64	Fitur hasil transformasi PCA (28 kolom)
Amount	Numerik	float64	Nominal transaksi
Class	Numerik (target)	int64	Transaksi fraud (1) atau normal (0)

Contoh 5 baris pertama dataset (sebagian kolom)

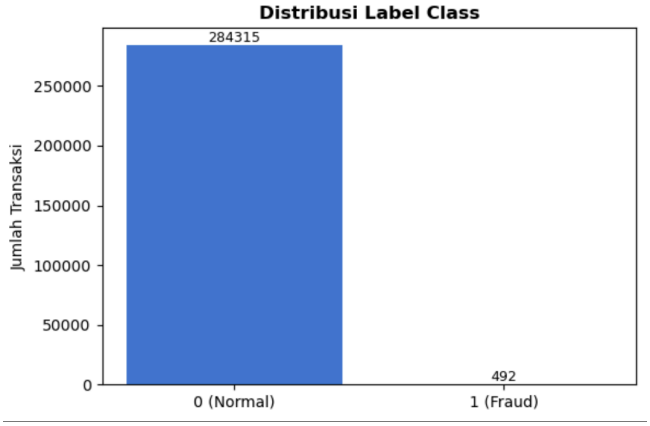
Atribut	Data 1	Data 2	Data 3	Data 4	Data 5
Time	0	0	1	1	2
V1	-1,360	1,192	-1,358	-0,966	-1,158
V2	-0,073	0,266	-1,340	-0,185	0,878
V3	2,536	0,166	1,773	1,793	1,549
V4	1,378	0,448	0,380	-0,863	0,403
V28	-0,021	0,015	-0,060	0,061	0,215
Amount	149,62	2,69	378,66	123,50	69,99
Class	0	0	0	0	0

Hasil pengecekan menunjukkan bahwa tidak ada nilai kosong (missing value) pada semua kolom. Terdapat 1.081 baris duplikat atau sekitar 0,38% dari seluruh data. Baris duplikat ini sudah dicek, tetapi tidak dihapus, sehingga jumlah data yang dipakai tetap 284.807 baris.

Atribut	Rata-rata	Std	Min	Median	Maks
Time	94.813,86	47.488,15	0	84.692	172.792
Amount	88,35	250,12	0	22,00	25.691,16

Nilai Time berkisar dari 0 sampai 172.792 detik, artinya data berisi transaksi selama sekitar 2 hari. Pada Amount, nilai rata-rata (88,35) jauh lebih besar dari median (22,00) dan nilai maksimumnya sangat tinggi, sehingga data miring ke kanan. Fitur V1 sampai V28 memiliki rata-rata mendekati 0 karena merupakan hasil PCA. Jika dilihat per kelas, rata-rata Amount transaksi fraud (122,21) lebih tinggi dari transaksi normal (88,29), tetapi mediannya justru lebih kecil (9,25 dibanding 22,00).

3.2 Distribusi Kelas Awal



Distribusi label Class menunjukkan bahwa 284.315 transaksi (99,827%) merupakan transaksi normal, sedangkan hanya 492 transaksi (0,173%) yang termasuk fraud. Perbandingannya sekitar 578 : 1, artinya untuk setiap 1 transaksi fraud terdapat sekitar 578 transaksi normal. Batang kelas fraud bahkan hampir tidak terlihat pada grafik. Data ini sangat tidak seimbang (imbalanced), sehingga jika tidak ditangani, model cenderung menebak semua transaksi sebagai normal.

3.3 Pembagian Data Latih dan Data Uji

Data dibagi menjadi data latih dan data uji dengan perbandingan 80:20.

Data	Jumlah baris	Normal (0)	Fraud (1)	Proporsi fraud
Data latih (80%)	227.845	227.451	394	0,173%
Data uji (20%)	56.962	56.864	98	0,172%

Karena memakai stratify=y, proporsi fraud pada data latih dan data uji tetap hampir sama dengan data asli, yaitu sekitar 0,17%. Data uji hanya berisi 98 transaksi fraud, sehingga setiap 1 fraud yang lolos sudah menurunkan recall sekitar 1%.

3.4 Pendekatan Penanganan Class Imbalance

Untuk menangani data yang tidak seimbang, peneliti mencoba dua teknik resampling. Kedua teknik hanya diterapkan pada data latih, sedangkan data uji tetap memakai distribusi asli agar hasil evaluasi menggambarkan kondisi yang sebenarnya. Jika resampling dilakukan sebelum data dibagi, data sintetis atau informasi dari data uji bisa ikut masuk ke data latih (data leakage), sehingga hasil evaluasi menjadi terlalu bagus.

1. **Random Undersampling**
   Data normal pada data latih diambil secara acak (tanpa pengembalian, random_state=42) sebanyak jumlah data fraud, yaitu 394 baris. Hasilnya, data latih menjadi 788 baris dengan perbandingan 1:1. Kekurangannya, sebanyak 227.057 baris data normal (99,8% dari data normal) dibuang.
2. **Oversampling SMOTE**
   SMOTE (Synthetic Minority Over-sampling Technique) membuat data fraud sintetis dengan cara memilih satu data fraud dan tetangga terdekatnya, lalu membuat titik baru di antara keduanya. SMOTE menambah 227.057 data fraud sintetis, sehingga data latih menjadi 454.902 baris dengan perbandingan 1:1. Data normal tidak ada yang dibuang.

Data	Normal (0)	Fraud (1)	Total
Data latih asli	227.451	394	227.845
Data latih undersampling	394	394	788
Data latih SMOTE	227.451	227.451	454.902
Data uji (tidak diubah)	56.864	98	56.962

Distribusi kelas sebelum dan sesudah resampling menunjukkan bahwa kedua teknik sama-sama menghasilkan data latih yang seimbang, tetapi ukurannya sangat berbeda. Undersampling membuat data latih menjadi sangat kecil (788 baris), sedangkan SMOTE membuat data latih menjadi dua kali lebih besar dari data latih asli.

3.5 Pembangunan Model

Model yang digunakan adalah XGBoost (XGBClassifier), yaitu salah satu ensemble method jenis gradient boosting. Pada gradient boosting, pohon keputusan dibuat satu per satu, dan setiap pohon baru belajar memperbaiki kesalahan dari pohon-pohon sebelumnya. Hasil prediksi akhirnya adalah gabungan dari semua pohon tersebut.

Untuk mencari parameter terbaik, digunakan GridSearchCV dengan Stratified K-Fold 5 bagian dan scoring F1. Tuning dilakukan pada data latih hasil undersampling.

Parameter	Nilai yang dicoba	Nilai terbaik
n_estimators	100 dan 200	200
learning_rate	0,05 dan 0,1	0,05
max_depth	3 dan 5	5

Total ada 8 kombinasi parameter yang masing-masing diuji dengan 5 fold. Skor cross validation terbaik adalah F1 = 0,950. Parameter terbaik ini kemudian dipakai juga untuk model tanpa resampling (dilatih dengan data latih asli) dan model SMOTE, sehingga ketiga model hanya berbeda pada data latihnya. Fitur tidak di-scaling karena model berbasis pohon tidak membutuhkan fitur dengan skala yang sama.

3.6 Performa Model pada Data Uji

Ketiga model dievaluasi pada data uji yang sama, yaitu 56.962 baris dengan distribusi asli. Metrik yang digunakan untuk kelas fraud adalah sebagai berikut.

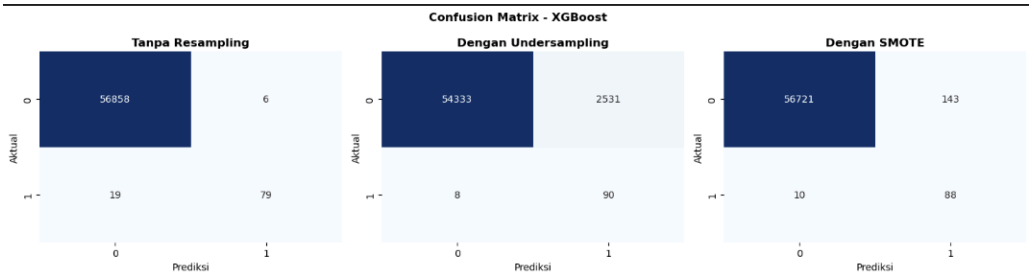
1. **Precision**: dari transaksi yang diprediksi fraud, berapa yang benar-benar fraud. Precision rendah berarti banyak transaksi normal yang salah dituduh fraud.
2. **Recall**: dari seluruh transaksi fraud, berapa yang berhasil terdeteksi. Recall rendah berarti banyak fraud yang lolos.
3. **F1-score**: rata-rata harmonik dari precision dan recall, yaitu $F1 = 2 \times P \times R / (P + R)$.
4. **AUC-ROC**: kemampuan model memisahkan kelas fraud dan normal di berbagai nilai threshold, tanpa bergantung pada satu threshold tertentu.

Model	Accuracy	Precision	Recall	F1-score	AUC-ROC
Tanpa resampling	1,000*	0,929	0,806	0,863	0,976
Undersampling	0,955	0,034	0,918	0,066	0,975
SMOTE	0,997	0,381	0,898	0,535	0,978

Model tanpa resampling memiliki precision dan F1-score tertinggi, model undersampling memiliki recall tertinggi tetapi precision dan F1-score paling rendah, sedangkan SMOTE berada di antara keduanya.

Model	TN	FP (salah tuduh)	FN (fraud lolos)	TP (fraud

				tertangkap)
Tanpa resampling	56.858	6	19	79
Undersampling	54.333	2.531	8	90
SMOTE	56.721	143	10	88



Pada confusion matrix, FP (false positive) adalah transaksi normal yang salah dituduh fraud, sedangkan FN (false negative) adalah transaksi fraud yang lolos tidak terdeteksi. Model tanpa resampling hanya salah tuduh 6 transaksi, tetapi meloloskan 19 dari 98 fraud. Model undersampling hanya meloloskan 8 fraud, tetapi salah tuduh 2.531 transaksi normal. Model SMOTE meloloskan 10 fraud dengan 143 salah tuduh.

3.7 Mengapa Accuracy Saja Tidak Cukup

Jika hanya melihat accuracy, ketiga model terlihat sangat bagus (0,955 sampai 1,000). Namun, karena fraud hanya 0,17% dari data, model yang selalu menebak "normal" untuk semua transaksi sudah mendapat accuracy 0,998 (56.864 dari 56.962 data uji), padahal tidak menangkap satu pun fraud.

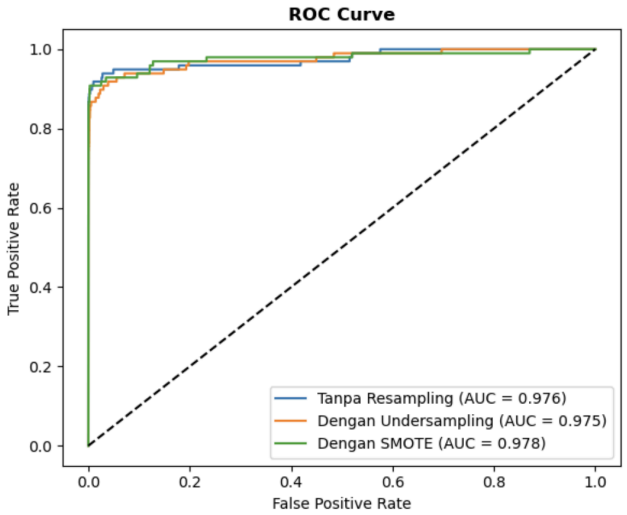
Model	Accuracy	Recall	Fraud tertangkap
Selalu menebak "normal"	0,998	0,000	0 dari 98
XGBoost tanpa resampling	0,9996	0,806	79 dari 98

Selisih accuracy antara model yang tidak berguna dan model yang bagus hanya sekitar 0,001. Selain itu, di balik accuracy 1,000 pada model tanpa resampling masih ada 19 dari 98 fraud yang lolos. Model undersampling bahkan memiliki accuracy paling rendah (0,955), padahal recall-nya paling tinggi. Accuracy menutupi kegagalan model pada kelas fraud, yang justru menjadi fokus utama. Oleh karena itu, penilaian model dalam penelitian ini memakai precision, recall, F1-score, dan AUC-ROC pada kelas fraud.

3.8 Analisis Perbandingan Model

Berdasarkan hasil evaluasi, resampling tidak otomatis membuat model lebih baik, tetapi

merupakan trade-off antara recall dan precision. Undersampling menaikkan recall dari 0,806 menjadi 0,918. Namun, salah tuduh ikut naik dari 6 menjadi 2.531, atau sekitar 230 salah tuduh untuk setiap 1 fraud tambahan, sehingga F1-score-nya hanya 0,066. AUC model tanpa resampling (0,976) dan undersampling (0,975) hampir sama. Jadi perbedaannya muncul dari threshold 0,5, karena model undersampling dilatih seolah-olah setengah datanya adalah fraud. SMOTE berada di tengah dengan recall 0,898 dan hanya 143 salah tuduh, karena SMOTE tidak membuang data normal. Peneliti juga mencoba SMOTE dengan StandardScaler, tetapi hasilnya lebih buruk (F1-score 0,374), sehingga yang dipakai adalah SMOTE tanpa scaling.



Kurva ROC ketiga model hampir berimpit dan sama-sama berada jauh di atas garis diagonal (tebakan acak).

Metrik	**Urutan model**
F1-score	Tanpa resampling (0,863) > SMOTE (0,535) > Undersampling (0,066)
Precision	Tanpa resampling (0,929) > SMOTE (0,381) > Undersampling (0,034)
Recall	Undersampling (0,918) > SMOTE (0,898) > Tanpa resampling (0,806)
AUC-ROC	SMOTE (0,978) > Tanpa resampling (0,976) > Undersampling (0,975)

Jadi, model terbaik bergantung pada prioritasnya. Jika prioritasnya precision atau F1-score (tidak ingin banyak salah tuduh), model tanpa resampling adalah pilihan terbaik. Jika prioritasnya menangkap fraud sebanyak mungkin dengan jumlah salah tuduh yang masih wajar, SMOTE lebih baik daripada undersampling. Undersampling 1:1 kalah dari SMOTE hampir di semua metrik, dan recall-nya hanya unggul 0,02.

4. Kesimpulan

Berdasarkan hasil praproses, pemodelan, dan evaluasi, dataset Credit Card Fraud Detection sangat tidak seimbang karena fraud hanya 0,173% dari seluruh transaksi. Karena itu accuracy tidak bisa dijadikan acuan, sebab model yang selalu menebak “normal” saja sudah mendapat accuracy 0,998. Undersampling dan SMOTE pada data latih memang menaikkan recall, tetapi precision ikut turun, sehingga F1-score tertinggi tetap dimiliki model tanpa resampling (0,863). AUC-ROC ketiga model hampir sama (0,975 sampai 0,978), jadi perbedaan hasilnya lebih banyak dipengaruhi threshold 0,5. Model tanpa resampling lebih cocok jika yang diutamakan precision atau F1-score, sedangkan SMOTE lebih baik daripada undersampling jika tujuannya menangkap fraud sebanyak mungkin. Penelitian selanjutnya dapat mencoba mengatur threshold atau menerapkan cost-sensitive learning.