Penerapan Association Rule pada Data Transaksi Online Retail menggunakan Algoritma Apriori

Maria Putu Evelyne Corena Puryatma
5054251011

Abstrak

Eksperimen ini mencari produk yang sering dibeli bersamaan pada dataset Online Retail (UCI), yaitu 541.909 baris transaksi toko online di Inggris periode Desember 2010 sampai Desember 2011. Setelah dibersihkan, data menjadi 19.973 invoice dengan 4.061 produk, lalu diproses dengan algoritma Apriori. Parameter awal (min_support 0,01 dan min_confidence 0,5) menghasilkan 816 aturan yang didominasi satu keluarga produk, sehingga parameter dinaikkan menjadi 0,015 dan 0,6 dan menghasilkan 97 aturan. Aturan dengan lift tertinggi (31,0 sampai 37,6) semuanya berasal dari produk satu seri, tetapi support-nya kecil (1,6 sampai 1,8% transaksi).
Kata kunci: association rule, Apriori, market basket analysis, support, confidence, lift.

1. Latar Belakang

Toko ritel online mencatat banyak transaksi setiap hari. Dari data tersebut, toko dapat mengetahui produk yang sering dibeli bersamaan (market basket analysis) untuk membuat paket bundling, menata produk, atau memberi rekomendasi. Pola ini dinyatakan sebagai aturan asosiasi $A \rightarrow B$, yang kekuatannya diukur dengan support (seberapa sering A dan B dibeli bersama), confidence (peluang B dibeli jika A dibeli), dan lift (seberapa kuat hubungan A dan B dibanding kebetulan).

1.1 Permasalahan yang Dibahas

1. Bagaimana kondisi dataset Online Retail dan pembersihan apa yang diperlukan sebelum analisis?
2. Berapa nilai min_support dan min_confidence yang tepat agar aturan yang dihasilkan dapat dianalisis?
3. Aturan apa yang paling kuat berdasarkan lift, dan apa artinya bagi toko?

2. Metodologi Penelitian

Penelitian dilakukan menggunakan Python dengan library pandas, matplotlib, dan mlxtend. Tahapannya sebagai berikut.

1. **Pengumpulan Data**
   Dataset Online Retail dari UCI Machine Learning Repository berisi 541.909 baris dan 8 kolom. Data dibaca dari file CSV yang isinya sama dengan file .xlsx.
2. **Pembersihan Data**
   Menghapus baris dengan Description kosong, transaksi batal (InvoiceNo diawali "C"), Quantity ≤ 0, dan item yang bukan produk.
3. **Persiapan Data**
   Produk dikelompokkan per invoice, lalu diubah ke bentuk one-hot (basket) menggunakan

TransactionEncoder.

4. **Penerapan Apriori**
   Frequent itemset dan aturan asosiasi dicari mulai dari min_support 0,01 dan min_confidence 0,5, lalu nilainya disesuaikan.
5. **Evaluasi**
   Aturan dinilai dengan support, confidence, dan lift, lalu tiga aturan terbaik dipilih berdasarkan lift.

3. Hasil dan Pembahasan

3.1 Data dan Pembersihan

Dari 8 kolom, yang relevan untuk association rule hanya InvoiceNo (transaksi) dan Description (produk). Nilai kosong terdapat pada CustomerID (135.080 baris, 24,9%) dan Description (1.454 baris, 0,3%). CustomerID tidak dipakai, sehingga nilai kosongnya dibiarkan.

Tahap	**Baris**	**Invoice**
Awal	541.909	25.900
Hapus Description kosong	540.455	24.446
Hapus transaksi batal (C)	531.167	20.610
Hapus Quantity ≤ 0	530.693	20.136
Hapus item non-produk	528.390	19.973

Setiap baris dengan Description kosong ternyata merupakan invoice tersendiri, sehingga jumlah invoice ikut turun 1.454. Spasi di akhir Description dirapikan, sehingga produk unik turun dari 4.077 menjadi 4.065. Item POSTAGE, DOTCOM POSTAGE, CARRIAGE, dan Manual juga dihapus karena berupa ongkos kirim atau input manual. Tanpa langkah ini, muncul 62 aturan yang berisi ongkos kirim.

3.2 Persiapan Data Transaksi

Data dikelompokkan per invoice menjadi 19.973 transaksi dengan rata-rata 26,5 produk per transaksi. Hasil one-hot encoding berupa basket berukuran 19.973 × 4.061, dengan nilai True jika produk dibeli pada invoice tersebut.

3.3 Penentuan min_support dan min_confidence

min_support	**conf 0,5**	**conf 0,6**	**conf 0,7**
0,010	816	484	261
0,015	182	**97**	45
0,020	60	30	13

0,030	11	8	3

Titik awal 0,01 dan 0,5 menghasilkan 1.820 frequent itemset dan 816 aturan. Jumlah ini terlalu banyak, karena 634 aturan (78%) support-nya di bawah 0,015 dan sepuluh aturan dengan lift tertinggi semuanya dari satu keluarga produk (HERB MARKER). Karena itu dipakai min_support 0,015 dan min_confidence 0,6, yang menghasilkan 701 frequent itemset dan 97 aturan. Nilai 0,02 ke atas tidak dipilih karena membuang pasangan yang jelas berkaitan (REGENCY TEA PLATE dan POPPY'S PLAYHOUSE, support sekitar 0,016), sedangkan 0,03 hanya menyisakan 3 sampai 11 aturan.

3.4 Evaluasi Aturan Asosiasi

Metrik	**Min**	**Median**	**Rata-rata**	**Maks**
Support	0,015	0,017	0,020	0,041
Confidence	0,600	0,679	0,707	0,909
Lift	5,838	15,019	15,161	37,579

Seluruh 97 aturan memiliki lift jauh di atas 1, artinya hubungan antarproduk bukan kebetulan. Namun support-nya kecil (median 1,7% transaksi), sehingga pola ini hanya muncul pada sebagian kecil pembeli. Karena aturan A → B dan B → A memiliki lift yang sama, tiga aturan terbaik diambil satu arah saja (confidence tertinggi).

No	**Aturan (A → B)**	**Support**	**Confidence**	**Lift**
1	REGENCY TEA PLATE GREEN → REGENCY TEA PLATE ROSES	0,016	0,837	37,6
2	POPPY'S PLAYHOUSE BEDROOM → POPPY'S PLAYHOUSE KITCHEN	0,016	0,740	33,9
3	SET/6 RED SPOTTY PAPER CUPS → SET/6 RED SPOTTY PAPER PLATES	0,018	0,818	31,0

1. **REGENCY TEA PLATE GREEN → ROSES.** Dari 381 invoice yang membeli piring hijau, 319 (84%) juga membeli motif mawar, atau 37,6 kali lebih besar dari peluang umum (2,2%). Toko dapat menjualnya sebagai paket set dan memajang semua motif

berdampingan.

2. **POPPY'S PLAYHOUSE BEDROOM → KITCHEN.** 74% pembeli bagian kamar tidur juga membeli bagian dapur. Mainan ini dikoleksi per ruangan, sehingga cocok untuk rekomendasi "lengkapi koleksi" atau bundling antar ruangan.
3. **RED SPOTTY PAPER CUPS → PLATES.** 82% pembeli gelas kertas polkadot merah juga membeli piringnya. Keduanya perlengkapan pesta yang dipakai bersamaan, sehingga dapat dijual sebagai paket pesta (cross-selling).

4. Kesimpulan

Setelah pembersihan, dataset Online Retail menjadi 19.973 invoice dengan 4.061 produk. Parameter awal 0,01 dan 0,5 menghasilkan terlalu banyak aturan yang didominasi satu keluarga produk, sehingga dipakai 0,015 dan 0,6 yang menghasilkan 97 aturan. Pola terkuat adalah pembelian produk satu seri atau satu desain secara bersamaan, dengan lift 31,0 sampai 37,6. Karena support-nya kecil (1,6 sampai 1,8%), aturan ini paling berguna untuk rekomendasi produk dan paket set, bukan untuk menggambarkan kebiasaan sebagian besar pembeli.