Analisis Pola Pembelian Berurutan pada Data Online Retail menggunakan Algoritma PrefixSpan

Maria Putu Evelyne Corena Puryatma
5054251011

Abstrak

Eksperimen ini mencari pola pembelian berurutan per pelanggan pada dataset Online Retail (UCI), yaitu transaksi toko online di Inggris periode Desember 2010 sampai Desember 2011. Setelah dibersihkan, data disusun menjadi 4.336 sequence pelanggan, lalu diproses dengan algoritma PrefixSpan yang ditulis sendiri. Titik awal min_support 0,01 menghasilkan 45.303 pola, sehingga min_support dinaikkan menjadi 0,03 dan menghasilkan 294 pola. Tiga pola dengan support tertinggi semuanya pembelian ulang produk yang sama, sedangkan pola dengan produk berbeda didominasi produk satu seri seperti LUNCH BAG.

Kata kunci: sequential pattern mining, PrefixSpan, sequence, support, confidence.

1. Latar Belakang

Pada tugas association rule, yang dicari adalah produk yang dibeli bersamaan dalam satu invoice, sehingga informasi waktu belum dipakai. Padahal pelanggan yang sama sering kembali berbelanja beberapa kali. Sequential pattern mining mencari urutan pembelian dari waktu ke waktu, misalnya pelanggan membeli produk A, lalu di transaksi berikutnya membeli produk B. Pola seperti ini berguna bagi toko untuk mengatur stok, mengirim pengingat pembelian ulang, dan merekomendasikan produk berikutnya. Pada penelitian ini digunakan algoritma PrefixSpan, dan kekuatan pola diukur dengan support dan confidence.

1.1 Permasalahan yang Dibahas

1. Bagaimana kondisi dataset dan pembersihan apa yang diperlukan agar data bisa disusun menjadi sequence per pelanggan?
2. Berapa nilai min_support yang tepat agar pola yang dihasilkan bisa dianalisis?
3. Pola berurutan apa yang paling sering muncul, dan apa artinya bagi toko?

2. Metodologi Penelitian

Penelitian dilakukan menggunakan Python dengan library pandas, numpy, dan matplotlib. Tahapannya sebagai berikut.

1. **Pengumpulan Data:** Online Retail.xlsx dibaca dengan pd.read_excel (541.909 baris, 8 kolom), lalu dicek dengan .head(), .shape, dan .info().
2. **Eksplorasi dan Pembersihan Data:** menghapus Description kosong, transaksi batal (InvoiceNo diawali "C"), Quantity ≤ 0, CustomerID kosong, dan item non-produk.
3. **Penyusunan Sequence:** data diurutkan per CustomerID dan InvoiceDate, satu invoice menjadi satu itemset, dan satu pelanggan menjadi satu sequence (list of list).
4. **Penerapan PrefixSpan:** dimulai dari min_support 0,01 (relatif terhadap jumlah pelanggan), lalu disesuaikan.
5. **Evaluasi Pola:** pola dinilai dengan support dan confidence, lalu dipilih tiga pola dengan support tertinggi.

3. Hasil dan Pembahasan

3.1 Data yang Digunakan

Dataset berisi 541.909 baris dan 8 kolom, dengan 25.900 invoice, 4.372 pelanggan, dan 4.223 nama produk unik. Untuk pola berurutan, hanya empat kolom yang dipakai.

Atribut	Tipe data	Keterangan	Peran dalam analisis
InvoiceNo	object	Nomor invoice (awalan C = batal)	1 invoice = 1 itemset
StockCode	object	Kode produk	Tidak dipakai
Description	object	Nama produk	Item dalam pola
Quantity	int64	Jumlah barang	Hanya untuk pembersihan
InvoiceDate	datetime64	Tanggal dan jam transaksi	Menentukan urutan
UnitPrice	float64	Harga satuan	Tidak dipakai
CustomerID	float64	ID pelanggan	1 pelanggan = 1 sequence
Country	object	Negara pelanggan	Tidak dipakai

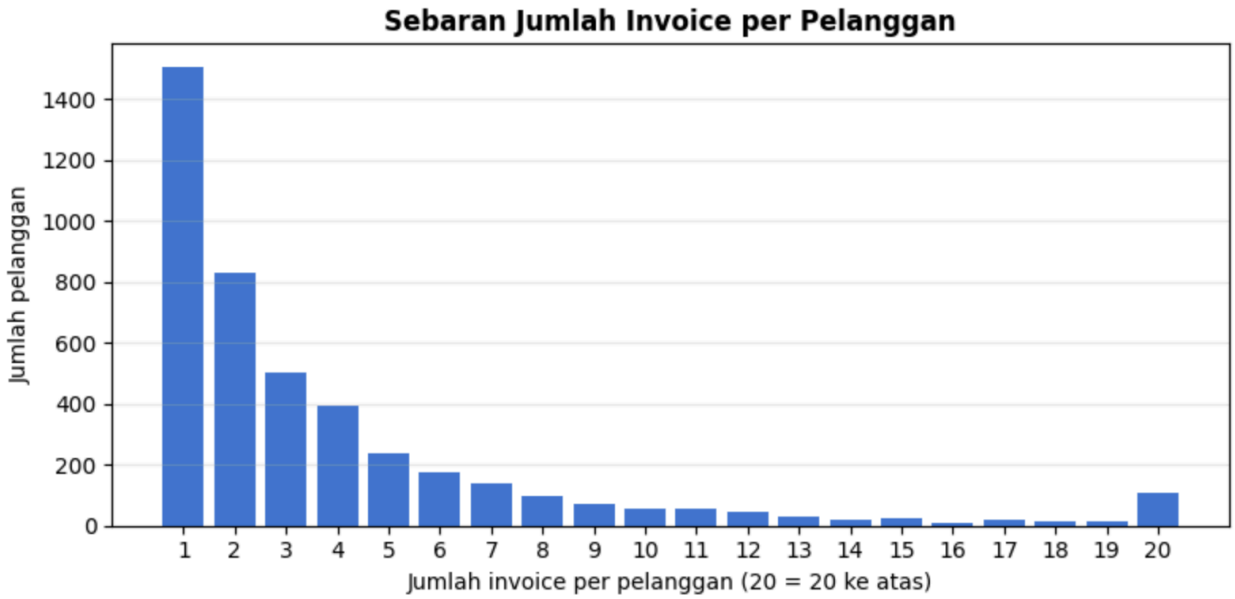
Nilai kosong hanya ada pada CustomerID (135.080 baris, 24,9%) dan Description (1.454 baris, 0,3%). Selain itu, terdapat 9.288 baris transaksi batal dan 10.624 baris dengan Quantity ≤ 0.

3.2 Pembersihan Data

Tahap	Baris	Invoice	Pelanggan
Awal	541.909	25.900	4.372
Hapus Description kosong	540.455	24.446	4.372
Hapus transaksi batal (C)	531.167	20.610	4.339
Hapus Quantity ≤ 0	530.693	20.136	4.339
Hapus CustomerID kosong	397.924	18.536	4.339
Hapus item non-produk	396.386	18.416	4.336

1. **Description kosong.** Semua 1.454 baris ini juga tidak punya CustomerID, jadi jumlah pelanggan tidak berubah.
2. **Transaksi batal.** Pelanggan turun 33 orang karena isi transaksinya hanya pembatalan.
3. **CustomerID kosong.** Tahap ini paling banyak mengurangi baris (530.693 menjadi 397.924), tetapi wajib dilakukan karena sequence disusun per pelanggan.
4. **Merapikan Description.** Spasi ganda dan spasi di ujung nama produk dirapikan, karena produk seperti "LUNCH BAG SUKI DESIGN" tadinya terbaca sebagai dua produk. Produk unik turun dari 3.877 menjadi 3.858.
5. **Item non-produk.** POSTAGE, DOTCOM POSTAGE, CARRIAGE, dan Manual dihapus karena berupa ongkos kirim atau input manual. Ada 3 pelanggan yang hilang karena isinya hanya ongkos kirim.

Data akhir berisi 396.386 baris, 18.416 invoice, 4.336 pelanggan, dan 3.854 produk.



Gambar 1. Sebaran jumlah invoice per pelanggan

Jumlah invoice per pelanggan nantinya menjadi panjang sequence. Nilainya memiliki median 2, rata-rata 4,2, dan maksimum 206, jadi sebarannya sangat miring ke kanan. Sebanyak 1.506 pelanggan (34,7%) hanya belanja sekali sehingga tidak punya urutan pembelian, tetapi tetap dihitung dalam penyebut support karena support dihitung relatif terhadap seluruh pelanggan. Di sisi lain, ada sekitar 100 pelanggan dengan 20 invoice atau lebih yang kemungkinan adalah pembeli grosir.

3.3 Penyusunan Sequence

Data diurutkan berdasarkan CustomerID dan InvoiceDate, lalu dikelompokkan per invoice. Satu itemset berisi produk unik dalam satu invoice, sedangkan Quantity tidak dipakai. Ada 30 invoice yang memiliki lebih dari satu waktu (beda beberapa menit), sehingga dipakai waktu yang paling awal. Hasilnya 18.416 itemset yang disusun menjadi 4.336 sequence (rata-rata 4,2 itemset per sequence) dan disimpan dalam bentuk list of list. Contohnya, sequence pelanggan 12347 berisi 7 invoice:

Invoice ke-	**Produk (3 pertama)**
1	3D DOG PICTURE PLAYING CARDS, AIRLINE BAG VINTAGE JET SET BROWN, ALARM CLOCK BAKELIKE CHOCOLATE, ...
2	3D DOG PICTURE PLAYING CARDS, 60 TEATIME FAIRY CAKE CASES, 72 SWEETHEART FAIRY CAKE CASES, ...
3	3D SHEET OF CAT STICKERS, 3D SHEET OF DOG STICKERS, AIRLINE BAG VINTAGE JET SET BROWN, ...
4 – 7	(dan seterusnya)

Pelanggan 12347 membeli 3D DOG PICTURE PLAYING CARDS di beberapa invoice berbeda. Pembelian ulang seperti inilah yang nantinya banyak muncul sebagai pola berurutan.

3.4 Penerapan PrefixSpan

Library prefixspan dari pip hanya bisa memproses sequence berisi item tunggal, padahal satu invoice berisi banyak produk, sedangkan SPMF membutuhkan Java. Karena itu PrefixSpan ditulis sendiri di

notebook dengan langkah berikut.

1. Hitung jumlah pelanggan per produk. Produk yang lolos min_support menjadi prefix (awal pola).
2. Potong sequence tiap pelanggan setelah invoice tempat prefix pertama kali muncul (projected database). Dipakai kemunculan pertama supaya sisa sequence paling panjang dan tidak ada pola yang terlewat.
3. Hitung lagi produk di sisa sequence, sambungkan yang lolos ke prefix, lalu ulangi sampai tidak ada produk yang lolos.

Pola berbentuk A → B → C, artinya pelanggan membeli A, lalu B di invoice berikutnya, lalu C. Produk dalam invoice yang sama tidak dianggap urutan karena sudah dibahas di association rule, jadi tidak ada pola seperti {A, B} → C.

- **Support** = pelanggan yang memiliki pola / 4.336. Satu pelanggan dihitung sekali walaupun polanya terjadi berkali-kali.
- **Confidence (A → B)** = support(A → B) / support(A), yaitu dari pembeli A, berapa persen yang setelahnya membeli B. Untuk pola tiga langkah, confidence = support(A → B → C) / support(A → B).

Contohnya, WHITE HANGING HEART T-LIGHT HOLDER dibeli oleh 856 pelanggan, dan 405 di antaranya membeli lagi di invoice berikutnya. Maka support = 405 / 4.336 = 0,093 dan confidence = 405 / 856 = 0,473. Pola satu langkah tidak ditampilkan karena tidak punya confidence dan isinya hanya produk laris.

3.5 Penentuan min_support

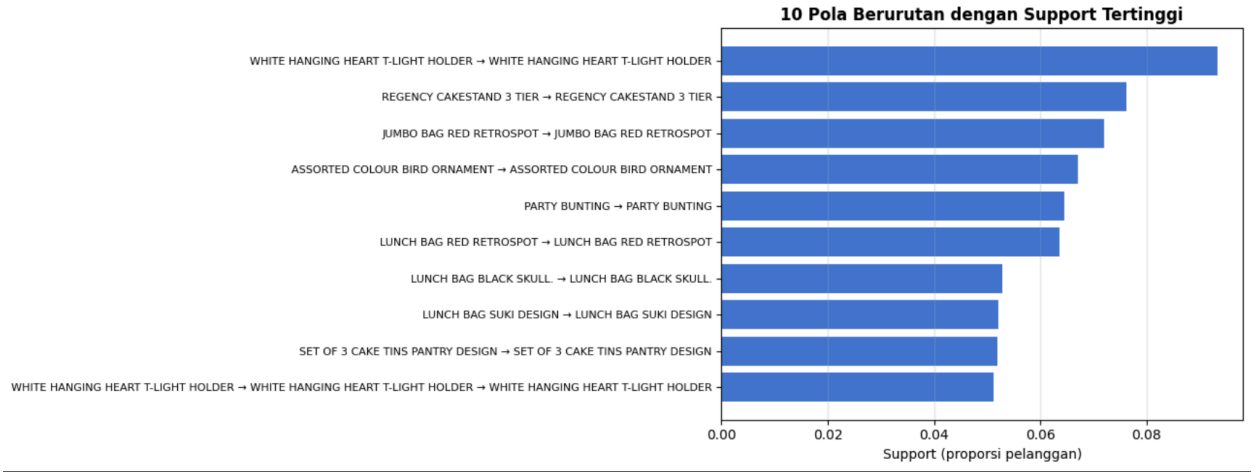
Titik awal min_support 0,01 (minimal 44 pelanggan) menghasilkan 45.303 pola dengan panjang sampai 7 langkah, dan 85% di antaranya support-nya di bawah 0,015. Untuk membandingkan nilai lain, hasil 0,01 cukup disaring tanpa menjalankan ulang, karena pola yang lolos support lebih besar pasti juga lolos 0,01.

min_support	Min. pelanggan	Jumlah pola	Panjang 2	Panjang ≥ 3	Produk berbeda
0,010	44	45.303	15.686	29.617	44.757
0,015	66	6.675	4.081	2.594	6.410
0,020	87	1.973	1.514	459	1.811
0,030	**131**	**294**	**283**	**11**	**228**
0,040	174	59	57	2	33
0,050	217	10	9	1	0

Jumlah pola pada 0,01 meledak karena ada pelanggan grosir yang belanja puluhan sampai ratusan kali, sehingga hampir semua kombinasi urutan produk terjadi pada mereka. Nilai 0,015 dan 0,02 masih menghasilkan ribuan pola, sedangkan 0,05 hanya 10 pola yang semuanya pembelian ulang produk yang sama. Karena itu dipakai min_support **0,03** (minimal 131 pelanggan), yang menghasilkan 294 pola: 283 pola dua langkah, 10 pola tiga langkah, 1 pola empat langkah, dan 228 pola berisi produk berbeda.

3.6 Evaluasi Pola Berurutan

Ke-294 pola memiliki support 0,030 sampai 0,093 (median 0,035) dan confidence 0,149 sampai 0,670 (median 0,346).



Gambar 2. Sepuluh pola berurutan dengan support tertinggi

Kesepuluh pola teratas semuanya pembelian ulang produk yang sama, salah satunya tiga kali berturut-turut (WHITE HANGING HEART T-LIGHT HOLDER). Tiga pola terbaik berdasarkan support adalah sebagai berikut.

No	Pola	Pelanggan	Support	Confidence
1	WHITE HANGING HEART T-LIGHT HOLDER → WHITE HANGING HEART T-LIGHT HOLDER	405	0,093	0,473
2	REGENCY CAKESTAND 3 TIER → REGENCY CAKESTAND 3 TIER	330	0,076	0,375
3	JUMBO BAG RED RETROSPOT → JUMBO BAG RED RETROSPOT	312	0,072	0,491

1. **WHITE HANGING HEART T-LIGHT HOLDER.** 405 pelanggan (9,3%) membeli produk ini lagi di transaksi berikutnya, atau 47,3% dari 856 pembelinya. Hampir setengah pembeli kembali membeli produk yang sama, jadi toko perlu menjaga stok dan bisa mengirim pengingat "beli lagi".
2. **REGENCY CAKESTAND 3 TIER.** 330 pelanggan (7,6%) membeli ulang, atau 37,5% dari 881 pembeli. Confidence-nya paling kecil, kemungkinan karena produknya lebih mahal dan awet. Namun pembeli ulangnya tetap banyak (kemungkinan toko atau reseller), sehingga cocok diberi harga grosir atau diskon pembelian ulang.
3. **JUMBO BAG RED RETROSPOT.** 312 pelanggan (7,2%) membeli ulang, dengan confidence tertinggi di antara ketiganya (49,1% dari 635 pembeli). Produk ini cocok dijual dalam paket grosir dan diberi pengingat stok ulang.

3.7 Pola Pelengkap

Tugas hanya meminta tiga pola berdasarkan support, tetapi pola dengan produk berbeda juga perlu dilihat karena lebih berguna untuk rekomendasi. Berikut lima pola produk berbeda dengan support tertinggi.

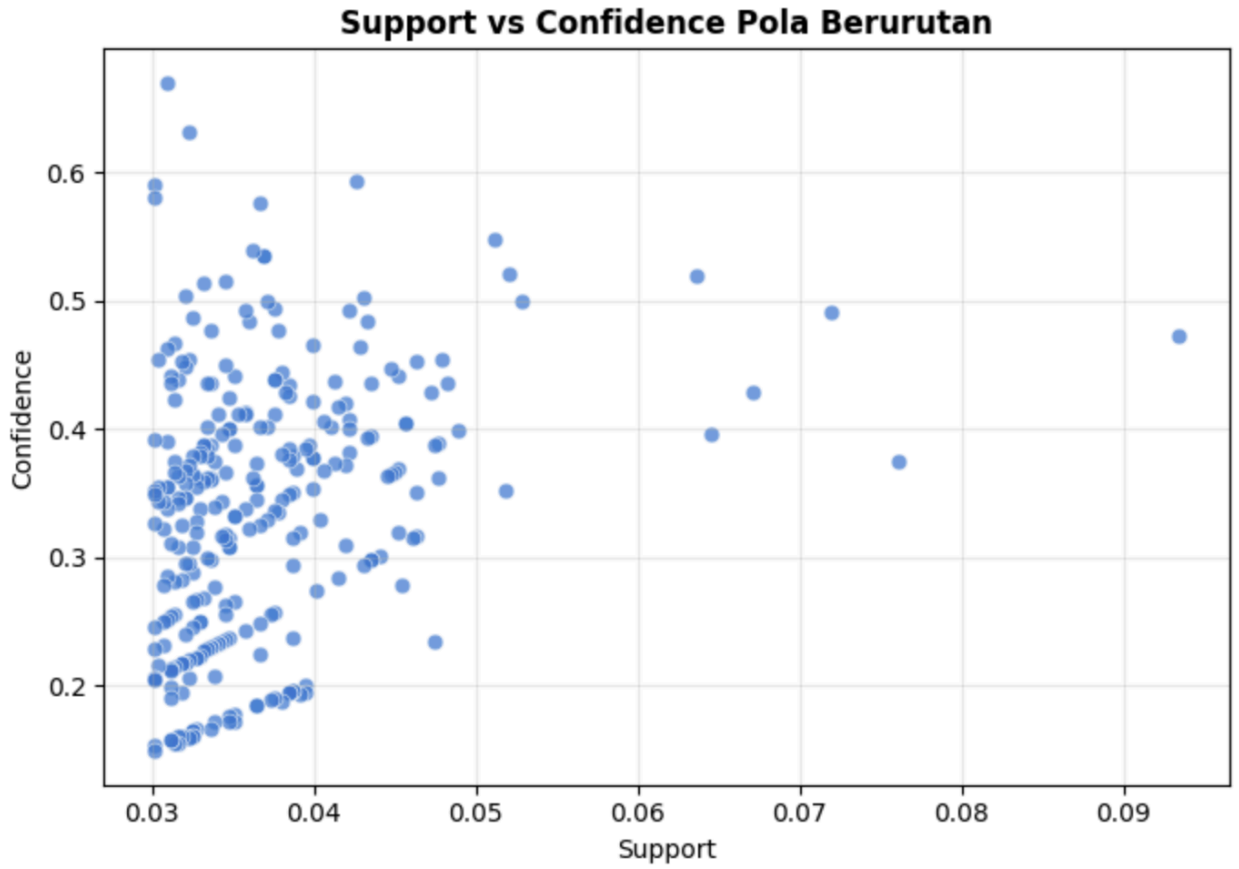
Pola	Pelanggan	Support	Confidence
LUNCH BAG RED RETROSPOT → LUNCH BAG BLACK SKULL.	212	0,049	0,398
LUNCH BAG CARS BLUE → LUNCH BAG RED RETROSPOT	209	0,048	0,436
LUNCH BAG BLACK SKULL. → LUNCH BAG RED	208	0,048	0,454

RETROSPOT			
LUNCH BAG RED RETROSPOT → LUNCH BAG SPACEBOY DESIGN	207	0,048	0,389
LUNCH BAG RED RETROSPOT → LUNCH BAG SUKI DESIGN	206	0,048	0,387

Kelimanya berasal dari seri LUNCH BAG dengan motif berbeda. Setelah membeli satu motif, sekitar 39 sampai 45% pelanggan kemudian membeli motif lain dari seri yang sama, sehingga toko bisa merekomendasikan motif lain di pembelian berikutnya. Berikut lima pola dengan confidence tertinggi.

Pola	**Pelanggan**	**Support**	**Confidence**
JUMBO BAG RED RETROSPOT → LUNCH BAG RED RETROSPOT → JUMBO BAG RED RETROSPOT	134	0,031	0,670
WHITE HANGING HEART T-LIGHT HOLDER (4 kali berturut-turut)	140	0,032	0,631
JUMBO BAG RED RETROSPOT (3 kali berturut-turut)	185	0,043	0,593
CANDLEHOLDER PINK HANGING HEART → WHITE HANGING HEART T-LIGHT HOLDER	131	0,030	0,590
LUNCH BAG SUKI DESIGN (3 kali berturut-turut)	131	0,030	0,580

Empat dari lima pola ini adalah pembelian ulang tiga atau empat kali, artinya makin sering pelanggan membeli ulang suatu produk, makin besar peluangnya membeli lagi. Pola CANDLEHOLDER PINK HANGING HEART → WHITE HANGING HEART T-LIGHT HOLDER juga menarik karena produknya berbeda tetapi masih satu tema (hanging heart).



Gambar 3. Support vs confidence pola berurutan

Sebagian besar pola berada di support 0,03 sampai 0,05, dengan confidence yang menyebar dari 0,15 sampai 0,67. Pola dengan confidence tertinggi justru support-nya kecil (sekitar 0,03), jadi support tinggi tidak selalu berarti confidence tinggi.

3.8 Perbandingan dengan Association Rule

Pada tugas association rule, aturan terkuat adalah produk satu seri yang dibeli dalam satu invoice, misalnya REGENCY TEA PLATE GREEN → ROSES. Pada sequential pattern, pola terkuat justru pembelian ulang produk yang sama di invoice berikutnya, yang tidak bisa ditemukan oleh association rule karena satu produk hanya muncul sekali dalam satu invoice. Persamaannya, keduanya menunjukkan bahwa produk satu seri sering dibeli oleh pelanggan yang sama, baik bersamaan maupun berurutan.

4. Kesimpulan

Setelah pembersihan, data Online Retail disusun menjadi 4.336 sequence pelanggan dengan rata-rata 4,2 invoice per pelanggan. Titik awal min_support 0,01 menghasilkan 45.303 pola karena pengaruh pelanggan grosir, sehingga dipakai 0,03 yang menghasilkan 294 pola. Pola paling umum adalah pembelian ulang produk laris, yaitu WHITE HANGING HEART T-LIGHT HOLDER, REGENCY CAKESTAND 3 TIER, dan JUMBO BAG RED RETROSPOT (support 7,2 sampai 9,3%, confidence 37,5 sampai 49,1%). Pola dengan produk berbeda berasal dari satu seri produk, terutama LUNCH BAG, sehingga cocok untuk rekomendasi motif lain. Support semua pola kecil karena sepertiga pelanggan hanya belanja sekali, jadi pola ini lebih berguna untuk pelanggan yang belanja berulang. Penelitian

selanjutnya dapat memisahkan pelanggan grosir dan pelanggan biasa, atau memberi batas jarak waktu antar pembelian.