Perbandingan Algoritma Clustering Lanjutan pada Data Palmer Penguins

Maria Putu Evelyne Corena Puryatma
5054251011

Abstrak

Eksperimen ini membandingkan empat algoritma clustering lanjutan, yaitu Agglomerative Clustering, DBSCAN, Gaussian Mixture Models (GMM), dan Spectral Clustering, pada dataset Palmer Penguins. Setelah dibersihkan, data berisi 342 penguin dengan empat fitur ukuran tubuh yang distandardisasi. Hasil clustering dievaluasi dengan Silhouette Score, Rand Index, NMI, dan uji kestabilan pada 90% data. GMM memberikan hasil yang paling sesuai dengan spesies asli (Rand Index 0,982, NMI 0,935) dan hanya salah mengelompokkan 5 penguin. DBSCAN memiliki Silhouette tertinggi (0,536), tetapi hanya menemukan 2 kluster karena Adelie dan Chinstrap tidak terpisah.

Kata kunci: clustering, Agglomerative, DBSCAN, GMM, Spectral Clustering, Palmer Penguins.

1. Latar Belakang

Clustering adalah teknik untuk mengelompokkan data berdasarkan kemiripan tanpa memakai label. Setiap algoritma punya cara berbeda dalam mendefinisikan kelompok: hierarchical (menggabungkan titik secara bertahap), density-based (berdasarkan kepadatan), model-based (berdasarkan distribusi peluang), dan spectral (berdasarkan graf kemiripan). Karena itu, hasil satu algoritma bisa berbeda dengan algoritma lain pada data yang sama. Dataset Palmer Penguins cocok untuk membandingkan keempatnya karena label spesiesnya sudah diketahui, sehingga hasil clustering bisa dicek kesesuaiannya dengan spesies asli. Label spesies hanya dipakai saat evaluasi dan tidak ikut dalam proses clustering.

1.1 Permasalahan yang Dibahas

1. Bagaimana kondisi dataset dan persiapan apa yang diperlukan sebelum clustering?
2. Bagaimana hasil pengelompokan Agglomerative, DBSCAN, GMM, dan Spectral Clustering pada data penguin?
3. Algoritma mana yang paling cocok untuk dataset ini berdasarkan Silhouette Score, Rand Index, NMI, dan uji kestabilan?

2. Metodologi Penelitian

Penelitian dilakukan menggunakan Python dengan library pandas, numpy, matplotlib, scikit-learn, dan scipy. Tahapannya sebagai berikut.

1. **Pengumpulan Data:** penguins.csv dibaca langsung dari link GitHub dengan pd.read_csv (344 baris, 8 kolom), lalu dicek dengan .head(), .shape, dan .info().
2. **Eksplorasi dan Pembersihan Data:** mengecek nilai kosong, menghapus baris yang kosong pada empat fitur atau species, melihat statistik deskriptif, jumlah data per spesies, dan scatter plot awal.
3. **Standardisasi Data:** empat fitur distandardisasi dengan StandardScaler (z-score).
4. **Penerapan Algoritma:** Agglomerative (3 kluster), DBSCAN (mulai dari eps 0,5 dan MinPts 5, lalu dicoba eps lain), GMM (3 komponen), dan Spectral Clustering (3 kluster).
5. **Evaluasi:** Silhouette Score, Rand Index dan NMI terhadap species, serta uji kestabilan pada 90% data acak sebanyak 3 kali.

3. Hasil dan Pembahasan

3.1 Data yang Digunakan

Dataset berisi 344 baris dan 8 kolom hasil pengukuran penguin di Kepulauan Palmer, Antartika. Sesuai ketentuan tugas, hanya empat kolom numerik yang dipakai sebagai fitur clustering.

Atribut	Tipe data	Keterangan	Peran dalam analisis
species	object	Adelie, Chinstrap, Gentoo	Label pembanding (evaluasi)
island	object	Pulau tempat pengamatan	Tidak dipakai
bill_length_mm	float64	Panjang paruh (mm)	Fitur clustering
bill_depth_mm	float64	Kedalaman paruh (mm)	Fitur clustering
flipper_length_mm	float64	Panjang sirip (mm)	Fitur clustering
body_mass_g	float64	Massa tubuh (gram)	Fitur clustering
sex	object	Jenis kelamin	Tidak dipakai
year	int64	Tahun pengamatan	Tidak dipakai

Nilai kosong ada pada keempat fitur numerik (masing-masing 2 baris) dan sex (11 baris), sedangkan species tidak ada yang kosong. Dua baris yang kosong di fitur numerik adalah baris yang sama (1 Adelie dan 1 Gentoo) dengan semua ukurannya kosong.

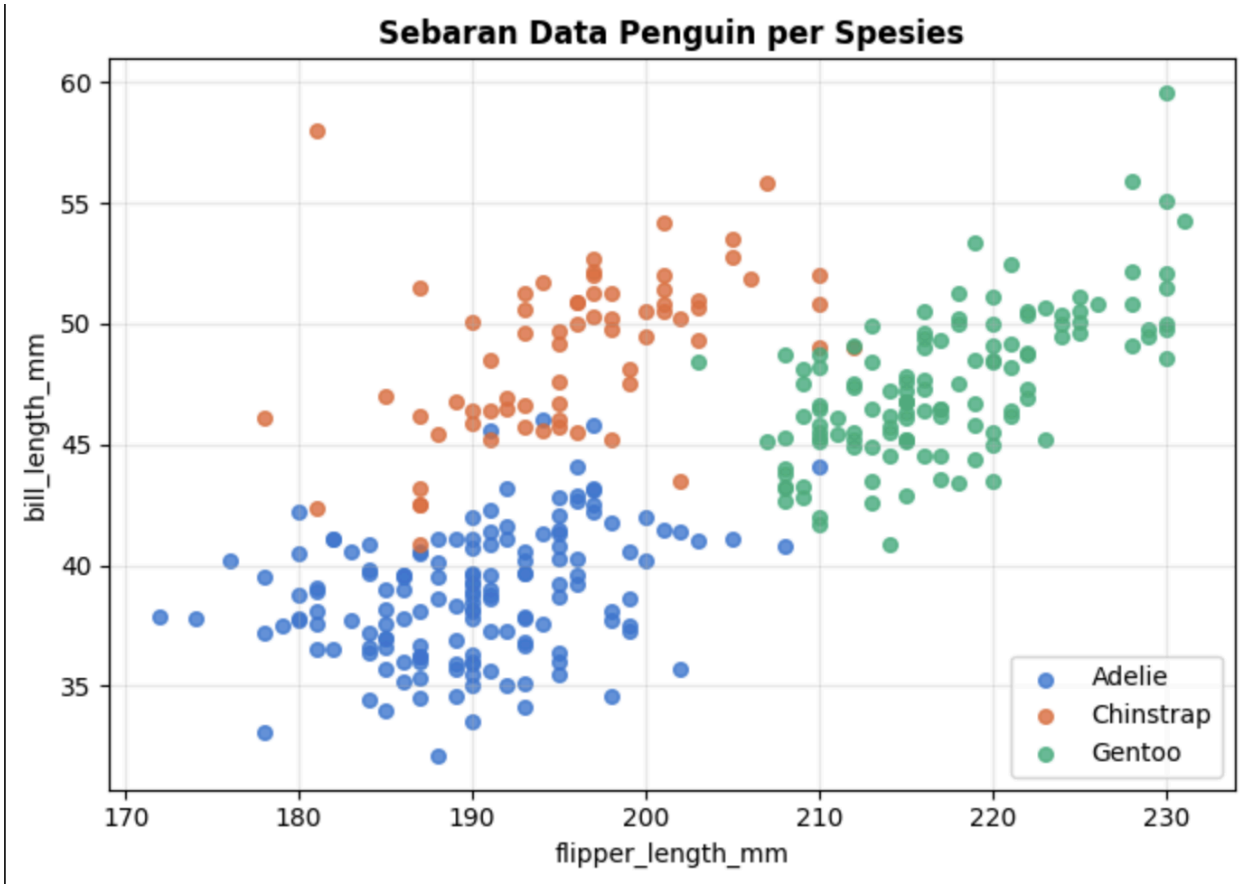
3.2 Pembersihan dan Eksplorasi Data

Baris hanya dihapus jika kosong pada empat fitur atau species, sehingga data turun dari 344 menjadi 342 baris. Baris dengan sex kosong tidak dihapus karena sex tidak dipakai. Kalau ikut dihapus, 9 baris lain yang ukurannya lengkap akan ikut terbuang.

Spesies	Jumlah	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g
Adelie	151	38,8	18,3	190,0	3.700,7
Chinstrap	68	48,8	18,4	195,8	3.733,1
Gentoo	123	47,5	15,0	217,2	5.076,0

Nilai fitur adalah rata-rata per spesies.

Jumlah data per spesies tidak seimbang, dengan Chinstrap paling sedikit (68). Dari statistik deskriptif, skala antar kolom berbeda jauh: body_mass_g memiliki rata-rata 4.201,75 gram dengan standar deviasi 801,95, sedangkan kolom lain hanya puluhan sampai ratusan mm (standar deviasi bill_depth_mm hanya 1,97). Kalau tidak distandardisasi, jarak antar titik hampir hanya ditentukan oleh body_mass_g.



Gambar 1. Sebaran data penguin per spesies (flipper_length_mm vs bill_length_mm)

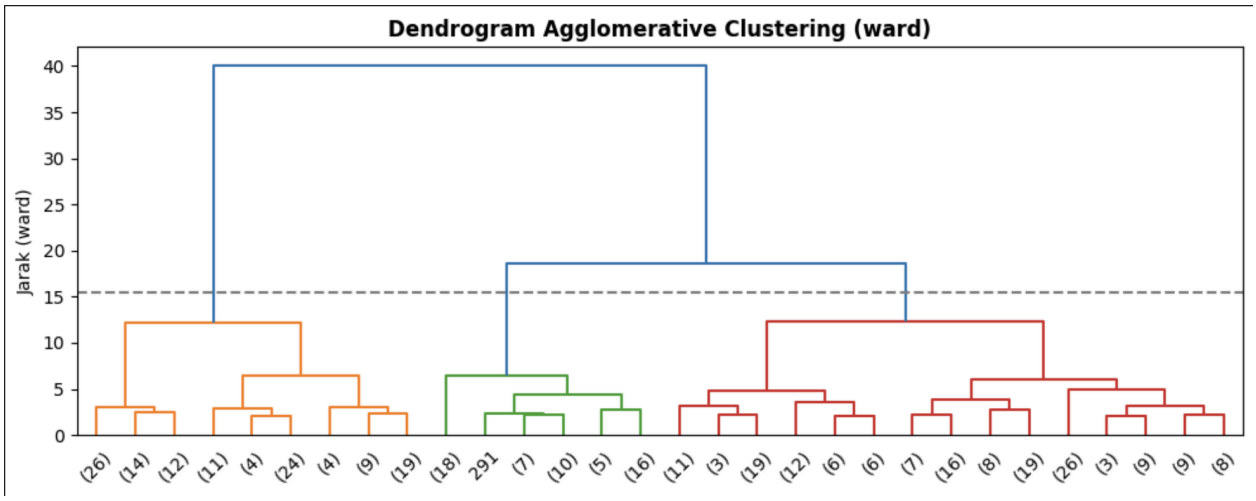
Gentoo terpisah jelas di sebelah kanan karena siripnya paling panjang (rata-rata 217,2 mm). Adelie dan Chinstrap memiliki panjang sirip yang mirip (190,0 dan 195,8 mm) dan bedanya terutama di panjang paruh (38,8 dan 48,8 mm), tetapi masih ada bagian yang tumpang tindih. Dari sini sudah terlihat bahwa bagian yang paling sulit dipisahkan adalah Adelie dan Chinstrap.

3.3 Standardisasi Data

Empat fitur dipisahkan sebagai X dan species sebagai y. X distandardisasi dengan z-score (StandardScaler) sehingga setiap kolom memiliki rata-rata 0 dan standar deviasi 1. Seluruh algoritma dijalankan pada data hasil standardisasi, tetapi scatter plot hasil clustering tetap memakai satuan asli (mm) agar mudah dibaca.

3.4 Agglomerative Clustering

Agglomerative Clustering memakai linkage **ward** (default scikit-learn). Pada setiap langkah, ward menggabungkan dua kluster yang paling sedikit menambah variasi di dalam kluster, sehingga cenderung menghasilkan kluster yang bulat dengan ukuran yang mirip.



Gambar 2. Dendrogram Agglomerative Clustering (ward)

Dendrogram hanya menampilkan 30 gabungan terakhir agar terbaca, dan angka dalam kurung menunjukkan jumlah titik di cabang tersebut. Tiga gabungan terakhir terjadi pada jarak 12,4, 18,6, dan 40,1. Garis potong diletakkan di antara 12,4 dan 18,6 (sekitar 15,5), sehingga data terbagi menjadi 3 kluster. Lompatan jarak dari 12,4 ke 18,6 cukup besar, jadi pembagian menjadi 3 kluster memang masuk akal. Hasilnya 162, 123, dan 57 penguin. Semua Gentoo (123) masuk satu kluster, tetapi 11 Chinstrap masuk ke kluster Adelie.

3.5 DBSCAN

DBSCAN mengelompokkan titik berdasarkan kepadatan. eps adalah radius tetangga, dan MinPts (min_samples) adalah jumlah tetangga minimal agar suatu titik menjadi titik inti. Titik yang tidak masuk ke kluster mana pun dianggap noise (label -1). MinPts dibuat tetap 5, lalu dicoba beberapa nilai eps.

eps	0,3	0,4	0,5	0,6	0,7	**0,8**	0,9	1,0
Jumlah kluster	4	10	4	2	2	**2**	2	2
Jumlah noise	317	171	69	33	16	**5**	2	1

Pada titik awal eps 0,5, DBSCAN menghasilkan 4 kluster dengan 69 noise (20% data). Chinstrap terpecah menjadi 2 kluster (15 dan 27 penguin) dan 23 Chinstrap menjadi noise. eps yang lebih kecil membuat hampir semua titik menjadi noise (eps 0,3) atau terpecah menjadi banyak kluster kecil (eps 0,4). Sementara itu, eps 0,6 sampai 1,0 stabil menghasilkan 2 kluster dengan noise yang terus turun.

Dipakai **eps 0,8** karena noise tinggal 5 titik (1,5%) dan jumlah kluster sudah tidak berubah sejak eps 0,6. Rand Index eps 0,5 memang lebih tinggi (0,853 dibanding 0,821), tetapi NMI-nya lebih rendah (0,663 dibanding 0,730) dan 69 titik terbuang sebagai noise. Dengan eps 0,8, kluster pertama berisi 150 Adelie dan 66 Chinstrap, sedangkan kluster kedua berisi 121 Gentoo. DBSCAN tidak bisa memisahkan Adelie dan Chinstrap karena kepadatan keduanya menyambung tanpa celah kosong, sedangkan Gentoo terpisah karena ada celah yang jelas. Ini kelemahan DBSCAN: jumlah kluster tidak bisa diatur dan hanya mengikuti kepadatan data.

3.6 Gaussian Mixture Models (GMM)

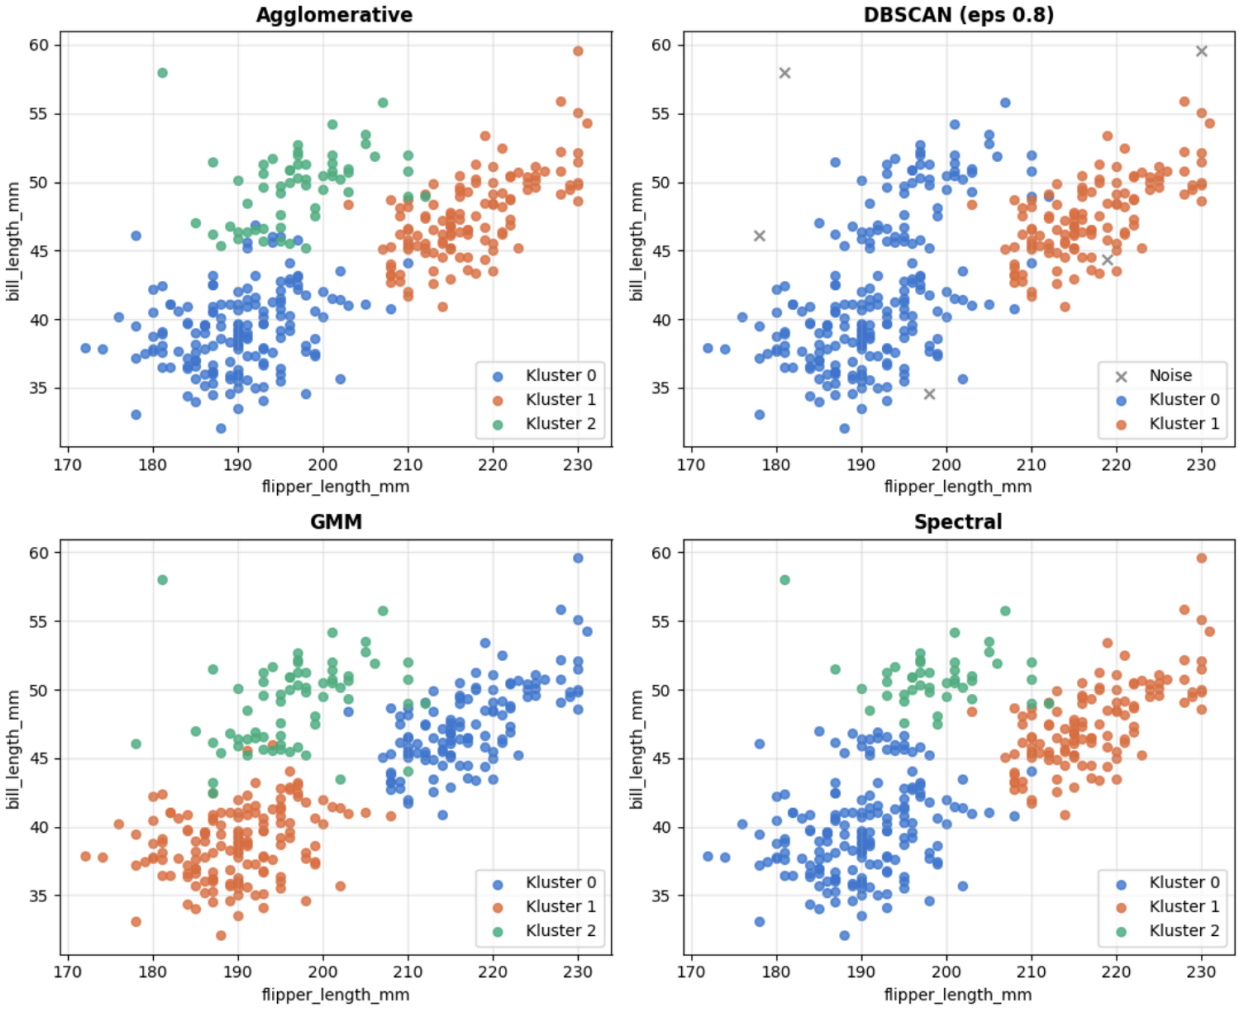
GMM menganggap data berasal dari campuran 3 distribusi normal (Gaussian). Setiap komponen punya

rata-rata dan kovarians sendiri, sehingga kluster boleh berbentuk lonjong atau miring dengan ukuran yang berbeda. Setiap titik mendapat peluang masuk ke tiap komponen, dan labelnya diambil dari peluang terbesar. Dipakai n_init=10, yaitu dicoba 10 titik awal lalu diambil hasil terbaik. Dengan pengaturan default (n_init=1), salah satu percobaan uji kestabilan sempat hanya mendapat Rand Index 0,76 karena terjebak titik awal yang buruk. Hasilnya 123, 152, dan 67 penguin. Semua Gentoo masuk satu kluster, dan hanya 5 penguin yang salah kelompok (2 Adelie dan 3 Chinstrap).

3.7 Spectral Clustering

Spectral Clustering membuat graf kemiripan antar titik (affinity rbf, default), lalu memotong graf tersebut menjadi 3 kelompok yang sambungan antar kelompoknya paling lemah. Cara ini bisa menangkap kluster yang bentuknya tidak bulat. Hasilnya 176, 123, dan 43 penguin, dengan 25 Chinstrap masuk ke kluster Adelie. Jumlah ini paling banyak di antara algoritma dengan 3 kluster. Affinity nearest_neighbors sempat dicoba dan hasilnya sama dengan Agglomerative (Rand Index 0,961), tetapi muncul peringatan "graph is not fully connected" karena Gentoo terpisah total, sehingga tetap dipakai affinity default.

3.8 Visualisasi Hasil Clustering



Gambar 3. Scatter plot hasil clustering keempat algoritma

Warna pada scatter plot menunjukkan nomor kluster, bukan spesies, jadi kluster 0 di satu algoritma tidak harus sama dengan kluster 0 di algoritma lain. Untuk DBSCAN, titik noise diberi tanda silang abu-abu.

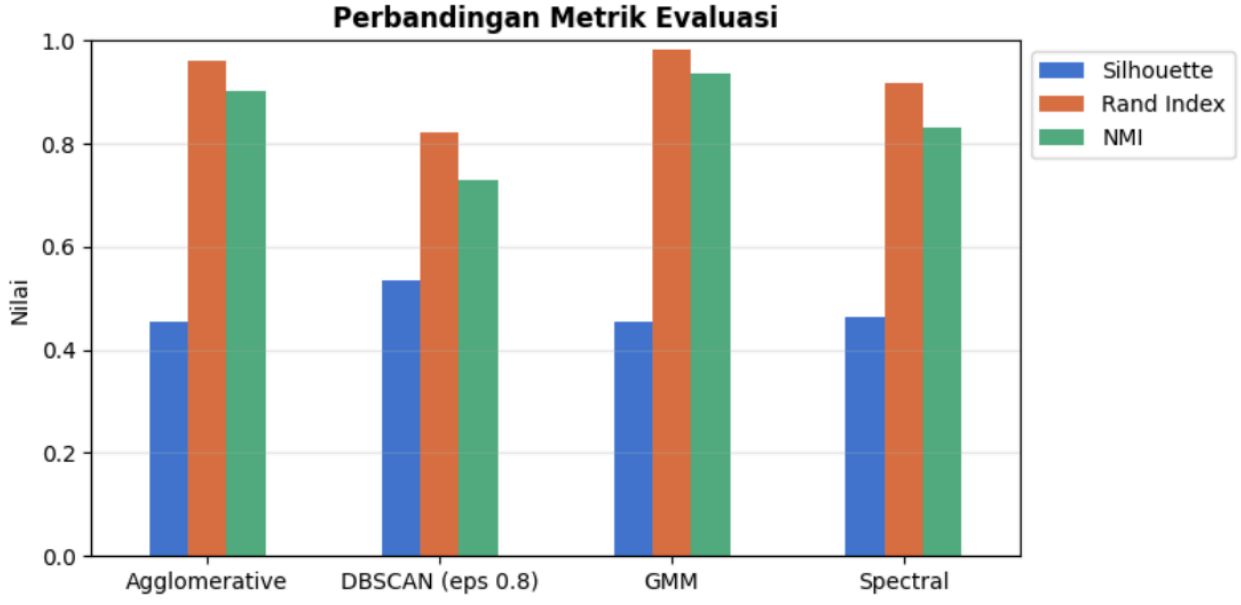
Keempat algoritma sama-sama memisahkan Gentoo di sebelah kanan (sirip panjang). Perbedaannya ada di batas Adelie dan Chinstrap: GMM membuat batas yang paling mirip dengan spesies asli, Agglomerative dan Spectral memasukkan sebagian Chinstrap ke kelompok Adelie, sedangkan DBSCAN menggabungkan keduanya menjadi satu kluster.

3.9 Evaluasi Hasil Clustering

- **Silhouette Score** (internal, tanpa species): seberapa dekat titik ke klusternya sendiri dibanding ke kluster lain, nilainya -1 sampai 1. Untuk DBSCAN, 5 titik noise dibuang sebelum dihitung.
- **Rand Index** (eksternal): persentase pasangan titik yang diperlakukan sama oleh kluster dan species, yaitu sama-sama satu kelompok atau sama-sama beda kelompok.
- **NMI** (eksternal): seberapa banyak informasi species yang tertangkap oleh kluster, nilainya 0 sampai 1.

Rand Index dan NMI tidak bergantung pada nomor kluster. Pada kedua metrik ini, 5 noise DBSCAN dihitung sebagai satu kelompok sendiri. Untuk uji kestabilan, diambil 90% data secara acak (307 titik) sebanyak 3 kali. Setiap algoritma dijalankan ulang, lalu labelnya dibandingkan dengan label data penuh pada titik yang sama menggunakan Rand Index (1 = sama persis).

Algoritma	**Kluster**	**Noise**	**Silhouette**	**Rand Index**	**NMI**	**Stabilitas (P1 / P2 / P3 → rata-rata)**
Agglomerative	3	0	0,454	0,961	0,901	0,968 / 0,972 / 0,971 → 0,970
DBSCAN (eps 0,8)	2	5	**0,536**	0,821	0,730	0,996 / 0,998 / 0,998 → 0,997
GMM	3	0	0,455	**0,982**	**0,935**	0,996 / 1,000 / 1,000 → 0,999
Spectral	3	0	0,462	0,917	0,831	1,000 / 1,000 / 1,000 → **1,000**



Gambar 4. Perbandingan Silhouette Score, Rand Index, dan NMI

GMM memiliki Rand Index dan NMI tertinggi, diikuti Agglomerative, Spectral, lalu DBSCAN. Dari tabel silang spesies dan kluster, Gentoo selalu dikelompokkan dengan benar oleh semua algoritma, dan kesalahan selalu terjadi antara Adelie dan Chinstrap. GMM hanya salah 5 penguin, Agglomerative 11, Spectral 25, sedangkan DBSCAN menggabungkan 66 Chinstrap ke kluster Adelie.

Silhouette ketiga algoritma dengan 3 kluster hampir sama (0,454 sampai 0,462). DBSCAN paling tinggi (0,536) karena hanya ada 2 kluster yang jaraknya jauh, bukan karena hasilnya lebih baik. Silhouette hanya mengukur seberapa terpisah kluster, bukan seberapa sesuai dengan spesies.

Pada uji kestabilan, semua algoritma mendapat nilai minimal 0,97, jadi perubahan kecil pada data tidak banyak mengubah hasil. Agglomerative paling goyang (0,970), kemungkinan karena hilangnya beberapa titik bisa mengubah urutan penggabungan pada ward.

4. Kesimpulan

Berdasarkan hasil evaluasi, **GMM adalah algoritma yang paling cocok** untuk dataset Palmer Penguins. GMM memiliki Rand Index (0,982) dan NMI (0,935) tertinggi, hanya salah mengelompokkan 5 dari 342 penguin, dan stabil (0,999). Alasannya, ukuran tubuh penguin saling berkorelasi (korelasi flipper_length_mm dan body_mass_g 0,87), sehingga sebaran tiap spesies berbentuk lonjong atau miring, dan jumlah tiap spesies berbeda (Chinstrap 68, Adelie 151). GMM bisa menangkap hal ini karena setiap kluster punya kovarians sendiri, sedangkan ward pada Agglomerative cenderung membuat kluster yang bulat dan seimbang.

Silhouette GMM memang bukan yang tertinggi, tetapi karena Adelie dan Chinstrap memang berdekatan, Silhouette semua algoritma dengan 3 kluster hanya sedang (sekitar 0,45). DBSCAN adalah algoritma yang paling tidak cocok untuk dataset ini karena kepadatan Adelie dan Chinstrap menyambung, sehingga hanya ditemukan 2 kluster.